

UNIVERSIDADE FEDERAL DE JUIZ DE FORA
FACULDADE DE ENGENHARIA
PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA ELÉTRICA

Arthur Santos Rodrigues

Previsão de Geração Fotovoltaica em Sistemas Twin-Plant: do Dataset BST-PV
à Comparação entre Modelos Clássicos e Baseados em *Large Language Models*

Juiz de Fora

2026

Arthur Santos Rodrigues

Previsão de Geração Fotovoltaica em Sistemas Twin-Plant: do Dataset BST-PV
à Comparação entre Modelos Clássicos e Baseados em *Large Language Models*

Dissertação apresentada ao Programa de Pós-Graduação em Engenharia Elétrica da Universidade Federal de Juiz de Fora como requisito parcial à obtenção do título de Mestre em Engenharia Elétrica. Área de concentração: Sistemas Eletrônicos, com ênfase em Automação e Ciência de Dados.

Orientador: Prof. Dr. Eduardo Pestana de Aguiar

Coorientador: Prof. Dr. Arthur Caio Vargas Pinto

Juiz de Fora

2026

Arthur Santos Rodrigues

Previsão de Geração Fotovoltaica em Sistemas Twin-Plant: do Dataset BST-PV
à Comparação entre Modelos Clássicos e Baseados em *Large Language Models*

Dissertação apresentada ao Programa de Pós-Graduação em Engenharia Elétrica da Universidade Federal de Juiz de Fora como requisito parcial à obtenção do título de Mestre em Engenharia Elétrica. Área de concentração: Sistemas Eletrônicos, com ênfase em Automação e Ciência de Dados.

Aprovada em (dia) de (mês) de (2026)

BANCA EXAMINADORA

Prof. Dr. Eduardo Pestana de Aguiar - Orientador
Universidade Federal de Juiz de Fora

Prof. Dr. Arthur Caio Vargas Pinto - Coorientador
Instituto Federal de Educação, Ciência e Tecnologia de
Minas Gerais

Dedicatória

AGRADECIMENTOS

Agradecimentos

RESUMO

A crescente penetração da geração fotovoltaica (PV) na matriz elétrica intensifica a necessidade de modelos de previsão de curto prazo cada vez mais precisos, robustos e capazes de separar a variabilidade meteorológica da dinâmica própria do sistema de geração. Esta dissertação apresenta uma linha de pesquisa estruturada em torno de uma planta fotovoltaica em configuração *Twin-Plant*, localizada no cerrado brasileiro, composta por dois subsistemas co-localizados que compartilham os mesmos módulos e inversores, porém diferem na tecnologia de montagem: um sistema de inclinação fixa e um sistema com rastreamento solar de eixo único. Esse arranjo experimental permite isolar, sob condições meteorológicas idênticas, o efeito da topologia de montagem sobre a previsibilidade da geração. O trabalho é desenvolvido em três etapas complementares. Primeiramente, é apresentado o dataset BST-PV (*Brazilian Savanna Twin-PV*), um conjunto de dados de alta resolução (5 minutos, aproximadamente 2,16 milhões de registros, 343 dias) que integra medições elétricas em nível de inversor com variáveis meteorológicas sincronizadas, acompanhado de um *benchmark* inicial de previsão com modelos clássicos e de aprendizado profundo. Em seguida, conduz-se uma análise comparativa sistemática entre os dois subsistemas ao longo das estações do ano, incorporando um pipeline de pré-processamento orientado por fundamentos físicos, engenharia de atributos baseada em defasagens temporais informadas por funções de autocorrelação e correlação cruzada, e otimização bayesiana de hiperparâmetros via Optuna. Por fim, avalia-se criticamente se modelos baseados em *Large Language Models* (Time-LLM, Chronos e Prophet) superam algoritmos clássicos de aprendizado de máquina (Random Forest, XGBoost e LightGBM) na mesma base de dados, em duas resoluções temporais. Os resultados indicam que a acurácia da previsão é fortemente sazonal, sendo superior no inverno e inferior no verão, e que o sistema com rastreamento apresenta, de forma geral, maior erro de previsão do que o sistema fixo, exceto em regimes de irradiância intermediária, como o outono. Adicionalmente, observa-se que os modelos clássicos de *ensemble* superam de forma sistemática e expressiva os modelos baseados em LLM em todos os cenários avaliados, evidenciando que, na presença de covariáveis meteorológicas de alta qualidade, a relação irradiância-potência é suficientemente capturada por regressores não lineares locais, sem que se observe vantagem competitiva das arquiteturas baseadas em atenção e em grandes modelos de linguagem nesse contexto. Em conjunto, os resultados reforçam a eficácia da configuração *Twin-Plant* como ferramenta experimental para isolar e analisar os efeitos da sazonalidade e da arquitetura de montagem sobre a previsibilidade da geração fotovoltaica, fornecendo subsídios práticos para a seleção de modelos em aplicações reais de monitoramento e despacho de energia solar.

Palavras-chave: energia fotovoltaica; previsão de séries temporais; aprendizado de máquina;

modelos de linguagem de grande escala; sistemas de rastreamento solar; *twin-plant*.

ABSTRACT

The growing penetration of photovoltaic (PV) generation in the electrical grid intensifies the need for increasingly accurate and robust short-term forecasting models capable of separating meteorological variability from the system’s own generation dynamics. This dissertation presents a research line structured around a photovoltaic plant in a *Twin-Plant* configuration, located in the Brazilian savanna, composed of two co-located subsystems that share the same modules and inverters but differ in mounting technology: a fixed-tilt system and a single-axis solar tracking system. This experimental arrangement makes it possible to isolate, under identical meteorological conditions, the effect of mounting topology on generation predictability. The work is developed in three complementary stages. First, the BST-PV (*Brazilian Savanna Twin-PV*) dataset is introduced, a high-resolution dataset (5-minute interval, approximately 2.16 million records, 343 days) that integrates inverter-level electrical measurements with synchronized meteorological variables, accompanied by an initial forecasting benchmark using classical and deep learning models. Next, a systematic comparative analysis is conducted between the two subsystems across the seasons of the year, incorporating a physics-informed preprocessing pipeline, temporal feature engineering based on lags informed by autocorrelation and cross-correlation functions, and Bayesian hyperparameter optimization via Optuna. Finally, it is critically evaluated whether Large Language Model (LLM)-based models (Time-LLM, Chronos, and Prophet) outperform classical machine learning algorithms (Random Forest, XGBoost, and LightGBM) on the same dataset, at two temporal resolutions. The results indicate that forecasting accuracy is strongly seasonal, being higher in winter and lower in summer, and that the tracking system generally exhibits higher forecasting error than the fixed system, except under intermediate irradiance regimes, such as autumn. Additionally, classical ensemble models are found to systematically and substantially outperform LLM-based models in all evaluated scenarios, showing that, in the presence of high-quality meteorological covariates, the irradiance-power relationship is sufficiently captured by local non-linear regressors, with no competitive advantage observed for attention-based architectures and large language models in this context. Taken together, the results reinforce the effectiveness of the *Twin-Plant* configuration as an experimental tool for isolating and analyzing the effects of seasonality and mounting architecture on photovoltaic generation predictability, providing practical guidance for model selection in real-world solar power monitoring and dispatch applications.

Keywords: photovoltaic energy; time series forecasting; machine learning; large language models; solar tracking systems; twin-plant.

LISTA DE ILUSTRAÇÕES

Vista estrutural representativa do sistema fotovoltaico com rastreamento solar de eixo único.	33
Arquitetura elétrica hierárquica da usina fotovoltaica <i>Twin-Plant</i> . O sistema é organizado em quatro camadas: geração DC (módulos e <i>strings</i>), conversão de potência (inversores), coleção em média tensão (eletrocentros e medição) e interconexão com a rede, na qual as saídas dos três blocos de geração são agregadas antes da injeção na rede de distribuição.	34
Arquitetura simplificada de aquisição de dados. Sensores meteorológicos e inversores alimentam <i>dataloggers</i> dedicados, que comunicam via Modbus a um sistema de borda baseado em CLP. Um motor em contêiner realiza <i>polling</i> sincronizado e transmite os dados a um banco MongoDB, com bufferização local para garantir persistência durante falhas de comunicação.	48
Pipeline de pré-processamento e avaliação. Os dados brutos dos inversores (A1) e da estação solarimétrica (A2) são integrados e submetidos a quatro etapas sequenciais de pré-processamento (preenchimento noturno, interpolação linear, imputação KNN e segmentação em trechos contínuos), seguidas por seleção de atributos, normalização, janelamento temporal, particionamento treino/validação/teste, treinamento dos modelos e avaliação por meio de RMSE, MAE e R^2	50
Estratégia metodológica progressiva desta dissertação. Os três experimentos compartilham a mesma base de dados e pipeline de pré-processamento, aprofundando sucessivamente a análise: de modelos de referência (Exp. 1), à engenharia de atributos e otimização (Exp. 2), à avaliação de modelos baseados em LLM em múltiplas resoluções (Exp. 3).	51
Mapa de calor do R^2 para as quatro estratégias de modelagem e três algoritmos de <i>ensemble</i> , por estação do ano e subsistema. Valores mais altos (tons mais escuros) indicam melhor desempenho.	54
Mapa de calor do Erro Absoluto Médio (EAM, em W) para as quatro estratégias de modelagem e três algoritmos de <i>ensemble</i> , por estação do ano e subsistema. Valores mais baixos (tons mais claros) indicam melhor desempenho.	55
Comparação de EAM, REQM e R^2 entre o sistema fixo e o sistema com rastreamento por estação do ano, utilizando a estratégia de otimização bayesiana. Barras agrupadas por algoritmo (RF, XGB, LGBM).	58
Impacto da estrutura física (fixa vs. rastreamento) em RMSE e R^2 para todos os modelos avaliados, resolução de 5 minutos. Os LLMs sofrem penalidade proporcionalmente maior na transição para o sistema com rastreamento.	61
Previsão vs. real para o sistema fixo (painel superior) e sistema com rastreamento (painel inferior), primeiros 168 pontos do conjunto de teste, resolução de 1 hora.	66

LISTA DE TABELAS

Tabela 1	– Comparativo de conjuntos de dados fotovoltaicos e meteorológicos representativos da literatura.	23
Tabela 2	– Especificações técnicas dos sistemas fotovoltaicos gêmeos.	32
Tabela 3	– Variáveis do <i>dataset</i> BST-PV, agrupadas por categoria funcional. Os grupos acima da linha divisória referem-se aos subsistemas de inversores (FIX e TK); os grupos abaixo referem-se à estação solarimétrica (SS).	49
Tabela 4	– Redução de dados ausentes (%) ao longo das etapas do pipeline de pré-processamento para os subsistemas fixo e com rastreamento.	51
Tabela 5	– Desempenho sazonal dos modelos de previsão (MAE e RMSE em W; R^2 adimensional) para os subsistemas fixo e com rastreamento. Melhores resultados por estação e subsistema em negrito.	52
Tabela 6	– Comparação entre a estratégia base e a melhor estratégia (Lag Features + Otimização Bayesiana com RF) em termos de MAE (W) e R^2 , por subsistema e estação.	56
Tabela 7	– Desempenho preditivo por modelo e subsistema na resolução de 5 minutos (partição 70/15/15). Melhores resultados por subsistema em negrito.	58
Tabela 8	– Desempenho preditivo por modelo e subsistema na resolução de 1 hora (partição 70/15/15). Melhores resultados por subsistema em negrito.	60
Tabela 9	– Evolução do desempenho preditivo ao longo dos três experimentos (MAE em W; R^2 adimensional). Resultados do melhor modelo de cada etapa, média das quatro estações.	63

LISTA DE ABREVIATURAS E SIGLAS

ABNT	Associação Brasileira de Normas Técnicas
ACF	Função de Autocorrelação (<i>Autocorrelation Function</i>)
ANFIS	Sistema de Inferência Neuro-Fuzzy Adaptativo (<i>Adaptive Neuro-Fuzzy Inference System</i>)
ANN	Rede Neural Artificial (<i>Artificial Neural Network</i>)
BiLSTM	Memória de Longo e Curto Prazo Bidirecional (<i>Bidirectional Long Short-Term Memory</i>)
BST-PV	<i>Brazilian Savanna Twin-PV</i> (dataset proposto)
CCF	Função de Correlação Cruzada (<i>Cross-Correlation Function</i>)
CNN	Rede Neural Convolutacional (<i>Convolutional Neural Network</i>)
DC	Corrente Contínua (<i>Direct Current</i>)
DHI	Irradiância Horizontal Difusa (<i>Diffuse Horizontal Irradiance</i>)
DNI	Irradiância Normal Direta (<i>Direct Normal Irradiance</i>)
EAM	Erro Absoluto Médio
GA	Algoritmo Genético (<i>Genetic Algorithm</i>)
GCR	Taxa de Cobertura do Solo (<i>Ground Cover Ratio</i>)
GHI	Irradiância Horizontal Global (<i>Global Horizontal Irradiance</i>)
GRI	Irradiância Refletida (<i>Ground-Reflected Irradiance</i>)
KNN	k -Vizinhos mais Próximos (<i>k-Nearest Neighbors</i>)
LAIC	Laboratório de Automação, Inteligência Artificial e Controle
LGBM/LightGBM	<i>Light Gradient Boosting Machine</i>
LLM	Modelo de Linguagem de Grande Escala (<i>Large Language Model</i>)
LSTM	Memória de Longo e Curto Prazo (<i>Long Short-Term Memory</i>)
MAE	Erro Absoluto Médio (<i>Mean Absolute Error</i>)
MPPT	Rastreamento do Ponto de Máxima Potência (<i>Maximum Power Point Tracking</i>)
MWp	Megawatt-pico
NWP	Previsão Numérica do Tempo (<i>Numerical Weather Prediction</i>)
PLC	Controlador Lógico Programável (<i>Programmable Logic Controller</i>)
POA	Irradiância no Plano do Array (<i>Plane-of-Array Irradiance</i>)
PV	Fotovoltaico (<i>Photovoltaic</i>)
R^2	Coefficiente de Determinação
REQM/RMSE	Raiz do Erro Quadrático Médio (<i>Root Mean Square Error</i>)
RF	<i>Random Forest</i>
TCN	Rede Convolutacional Temporal (<i>Temporal Convolutional Network</i>)
TPE	Estimador de Parzen com Estrutura em Árvore (<i>Tree-structured Parzen Estimator</i>)
UFJF	Universidade Federal de Juiz de Fora
WT	Transformada <i>Wavelet</i> (<i>Wavelet Transform</i>)
XGBoost	<i>Extreme Gradient Boosting</i>

LISTA DE SÍMBOLOS

y_i	Valor observado da variável alvo na amostra i
$\hat{y}_i$	Valor predito pelo modelo para a amostra i
$\bar{y}$	Média dos valores observados
n	Número total de amostras
k	Número de vizinhos considerados no método KNN
$ r $	Módulo do coeficiente de correlação de Pearson

SUMÁRIO

1	INTRODUÇÃO	16
1.1	CONTEXTUALIZAÇÃO E MOTIVAÇÃO	16
1.2	LINHA DE PESQUISA E ORGANIZAÇÃO DO TRABALHO	17
1.3	OBJETIVOS	18
1.3.1	Objetivo Geral	18
1.3.2	Objetivos Específicos	18
1.4	CONTRIBUIÇÕES	19
1.5	ORGANIZAÇÃO DO TEXTO	19
2	REVISÃO DA LITERATURA	21
2.1	CONJUNTOS DE DADOS PARA PESQUISA FOTOVOLTAICA	21
2.1.1	Categorias de Dados Fotovoltaicos	21
2.1.2	Conjuntos de Dados Relevantes na Literatura	22
2.1.3	Lacunas Identificadas e Motivação para o BST-PV	23
2.2	PREVISÃO DE GERAÇÃO FOTOVOLTAICA COM APRENDIZADO DE MÁQUINA	24
2.2.1	Abordagens Iniciais e Métodos Clássicos	24
2.2.2	Modelos de Ensemble para Previsão Fotovoltaica	24
2.2.3	Engenharia de Atributos Temporais	25
2.2.4	Redes Neurais Profundas e Arquiteturas Híbridas	26
2.2.5	Sazonalidade e Topologia de Montagem como Fatores de Previsibilidade	27
2.3	MODELOS BASEADOS EM <i>LARGE LANGUAGE MODELS</i> PARA SÉRIES TEMPORAIS	27
2.3.1	Arquiteturas LLM para Previsão de Séries Temporais	28
2.3.2	Limitações dos LLMs em Previsão Fotovoltaica	29
2.3.3	Posicionamento dos LLMs no Estado da Arte	29
2.4	SÍNTESE E POSICIONAMENTO DESTA DISSERTAÇÃO	30
3	MATERIAIS E MÉTODOS	31
3.1	SISTEMA FOTOVOLTAICO EXPERIMENTAL	31
3.1.1	Caracterização do Sítio e Clima	31
3.1.2	Especificações Técnicas dos Subsistemas	31
3.1.2.1	Sistema de Estrutura Fixa (Planta A)	32
3.1.2.2	Sistema com Rastreamento Solar de Eixo Único (Planta B)	32
3.1.3	Arquitetura Elétrica	33
3.1.4	Instrumentação Meteorológica	34
3.1.5	Arquitetura de Aquisição e Armazenamento de Dados	35
3.2	O <i>DATASET</i> BST-PV	36
3.2.1	Descrição Geral	36

3.2.2	Volume e Cobertura Temporal	36
3.2.3	Variáveis Disponíveis	37
3.2.4	Qualidade e Estatística dos Dados	37
3.3	PIPELINE DE PRÉ-PROCESSAMENTO	37
3.3.1	Integração e Reamostragem	38
3.3.2	Preenchimento Noturno por Algoritmo Astronômico	38
3.3.3	Interpolação Linear para Lacunas Curtas	38
3.3.4	Imputação Multivariada por KNN	39
3.3.5	Resultado do Pré-processamento e Segmentação	40
3.4	EXPERIMENTO 1: MODELOS DE REFERÊNCIA COM JANELA DESLI- ZANTE	40
3.4.1	Seleção de Atributos	40
3.4.2	Normalização	41
3.4.3	Janela Deslizante e Particionamento	41
3.4.4	Modelos Avaliados	41
3.4.4.1	Métodos de <i>Ensemble</i>	42
3.4.4.2	Rede Neural Recorrente	42
3.4.5	Métricas de Avaliação	42
3.5	EXPERIMENTO 2: ENGENHARIA DE ATRIBUTOS TEMPORAIS E OTIMIZAÇÃO BAYESIANA	43
3.5.1	Estratégias de Modelagem Progressivas	43
3.5.2	Engenharia de Atributos por Defasagem Temporal	43
3.5.2.1	Defasagens da Variável Alvo	43
3.5.2.2	Defasagens das Variáveis Meteorológicas	44
3.5.2.3	Atributos Complementares	44
3.6	EXPERIMENTO 3: MODELOS BASEADOS EM LLM E COMPARAÇÃO MULTI-ESCALA	44
3.6.1	Base de Dados e Particionamento	45
3.6.2	Modelos Avaliados	45
3.6.2.1	Modelos Clássicos de <i>Ensemble</i> (grupo de referência)	45
3.6.2.2	Modelos Baseados em LLM e Abordagens Alternativas Emergentes	45
3.6.3	Métricas e Protocolo de Avaliação	46
3.7	SÍNTESE DA ESTRATÉGIA METODOLÓGICA	46
4	RESULTADOS E DISCUSSÃO	52
4.1	EXPERIMENTO 1: MODELOS DE REFERÊNCIA COM JANELA DESLI- ZANTE	52
4.1.1	Desempenho Geral dos Modelos	52
4.1.2	Influência da Sazonalidade	53
4.1.3	Influência da Topologia de Montagem	53

4.2	EXPERIMENTO 2: ENGENHARIA DE ATRIBUTOS TEMPORAIS E OTIMIZAÇÃO BAYESIANA	54
4.2.1	Impacto das Estratégias de Modelagem	54
4.2.2	Contribuição de Cada Componente Metodológico	55
4.2.3	Análise das Defasagens por Variável	56
4.2.4	Padrão Sazonal e por Topologia no Experimento 2	57
4.3	EXPERIMENTO 3: MODELOS BASEADOS EM LLM VERSUS ALGORITMOS CLÁSSICOS	57
4.3.1	Resultados Quantitativos — Resolução de 5 Minutos	57
4.3.2	Resultados Quantitativos — Resolução de 1 Hora	59
4.3.3	Impacto Diferencial da Estrutura de Montagem sobre os Modelos	60
4.3.4	Análise Qualitativa das Previsões	61
4.3.5	Diagnóstico das Limitações Arquiteturais dos LLMs	61
4.3.6	Considerações sobre Custo Computacional	62
4.4	SÍNTESE INTEGRADA DOS TRÊS EXPERIMENTOS	63
4.4.1	Evolução do Desempenho ao Longo da Pesquisa	63
4.4.2	Respostas às Questões de Pesquisa	64
4.4.3	Implicações Práticas para Sistemas de Monitoramento e Despacho . . .	65
5	CONCLUSÃO	67
5.1	CONCLUSÕES GERAIS	67
5.2	CONTRIBUIÇÕES DA DISSERTAÇÃO	68
5.3	LIMITAÇÕES DO TRABALHO	70
5.4	TRABALHOS FUTUROS	72
	REFERÊNCIAS	74

1 INTRODUÇÃO

1.1 CONTEXTUALIZAÇÃO E MOTIVAÇÃO

A transição global em direção a fontes renováveis de energia tem acelerado de forma expressiva a implantação de sistemas de geração fotovoltaica (PV). De acordo com o relatório *Renewables 2025* da Agência Internacional de Energia, a capacidade global de geração renovável deve dobrar até 2030, com um acréscimo próximo de 4.600 gigawatts (GW), dos quais cerca de 80% é atribuído à energia solar fotovoltaica (1). Esse crescimento acelerado, porém, não é isento de desafios: a geração fotovoltaica é intrinsecamente intermitente e fortemente dependente de fatores meteorológicos como cobertura de nuvens, umidade e temperatura, que provocam flutuações rápidas na potência injetada na rede (2). Essa variabilidade impacta diretamente a estabilidade da rede elétrica, o despacho econômico e o planejamento energético, tornando a previsão de geração solar de curto prazo um elemento crítico para a integração segura e eficiente de fontes renováveis ao sistema elétrico (3).

Para que modelos de previsão sejam desenvolvidos e validados de forma confiável, é necessário dispor de dados de alta qualidade que capturem simultaneamente a dinâmica meteorológica e o comportamento elétrico interno dos sistemas fotovoltaicos. Entretanto, a literatura ainda apresenta uma lacuna relevante nesse aspecto: a maioria dos conjuntos de dados publicamente disponíveis fornece apenas medições agregadas em nível de planta, baseia-se em irradiância estimada por satélite, ou dispõe de resolução temporal insuficiente para capturar transientes de nuvens relevantes para previsão intra-horária (4, 5). Além disso, faltam dados de comparação direta entre diferentes tecnologias de montagem – como estruturas fixas e sistemas com rastreamento solar – operando sob condições meteorológicas idênticas, o que dificulta isolar os efeitos não lineares introduzidos pelos algoritmos de rastreamento (por exemplo, estratégias de *backtracking*) da variabilidade puramente atmosférica.

Paralelamente à questão dos dados, a evolução das técnicas de modelagem para previsão de geração fotovoltaica tem seguido uma trajetória que vai de modelos estatísticos clássicos a arquiteturas de aprendizado profundo cada vez mais sofisticadas, incluindo redes recorrentes, mecanismos de atenção e, mais recentemente, modelos baseados em *Large Language Models* (LLMs) adaptados para séries temporais numéricas (6, 7). Embora esses modelos tenham demonstrado capacidades notáveis em tarefas de linguagem natural, sua eficácia relativa frente a algoritmos clássicos de aprendizado de máquina em cenários reais de previsão fotovoltaica – especialmente em plantas com diferentes configurações estruturais – permanece pouco explorada na literatura.

É nesse cenário que se insere a presente dissertação, que tem como eixo central uma planta fotovoltaica de utilidade em configuração *Twin-Plant*, localizada na região

do cerrado brasileiro. Essa instalação é composta por dois subsistemas co-localizados que compartilham os mesmos módulos fotovoltaicos e os mesmos inversores, mas diferem exclusivamente na tecnologia de montagem: um sistema de estrutura fixa e um sistema com rastreamento solar de eixo único horizontal. Essa configuração experimental controlada elimina fontes externas de variabilidade entre os dois subsistemas, permitindo isolar, de forma rigorosa, o efeito da arquitetura de montagem sobre o comportamento da série temporal de potência gerada e, por consequência, sobre a dificuldade de sua previsão.

1.2 LINHA DE PESQUISA E ORGANIZAÇÃO DO TRABALHO

A pesquisa que fundamenta esta dissertação foi conduzida em três etapas progressivas e complementares, cada uma materializada em uma publicação científica específica, e que juntas compõem uma única linha investigativa coerente sobre previsão de geração fotovoltaica em sistemas *Twin-Plant*.

Na primeira etapa, foi construído e caracterizado o *dataset* BST-PV (*Brazilian Savanna Twin-PV*), um conjunto de dados de alta resolução temporal (5 minutos) que integra, de forma sincronizada, medições elétricas em nível de inversor de ambos os subsistemas com variáveis meteorológicas obtidas de uma estação solarimétrica instalada no local. Essa etapa teve como objetivo suprir a ausência, identificada na literatura, de conjuntos de dados abertos que combinem simultaneamente (i) medições elétricas em nível de inversor, (ii) variáveis meteorológicas de alta frequência e (iii) uma configuração *twin-plant* controlada. Um *benchmark* preliminar de previsão de potência ativa foi conduzido nesta etapa, utilizando modelos clássicos de *ensemble* (*Random Forest*, XGBoost e LightGBM) e uma rede LSTM, estabelecendo métricas de referência para trabalhos futuros.

Na segunda etapa, partindo do *dataset* consolidado, foi conduzida uma análise comparativa sistemática entre os subsistemas fixo e com rastreamento, ao longo das quatro estações do ano, com foco explícito em entender como a sazonalidade e a dinâmica do sistema de rastreamento interagem para determinar a previsibilidade da geração. Essa etapa incorporou um pipeline de pré-processamento orientado por fundamentos físicos (zeragem noturna baseada em cálculos astronômicos, interpolação linear e imputação multivariada via KNN), bem como uma estratégia avançada de engenharia de atributos temporais baseada em defasagens (*lag features*) informadas pelas funções de autocorrelação (ACF) e correlação cruzada (CCF) das variáveis envolvidas, além de otimização bayesiana de hiperparâmetros via *Optuna*.

Na terceira etapa, o foco da investigação foi deslocado para uma questão de caráter mais crítico e atual: avaliar se modelos baseados em *Large Language Models* – especificamente Time-LLM, Chronos e Prophet – são capazes de superar algoritmos clássicos de aprendizado de máquina (*Random Forest*, XGBoost e LightGBM) na previsão de geração fotovoltaica da mesma planta *twin-plant*, em duas resoluções temporais distintas

(5 minutos e 1 hora). Essa etapa buscou posicionar criticamente as arquiteturas emergentes baseadas em LLM frente ao estado da arte estabelecido, identificando em que condições – se em alguma – essas arquiteturas oferecem vantagem competitiva real.

O conjunto dessas três etapas permite que esta dissertação avance de uma contribuição de infraestrutura de dados (o *dataset* BST-PV) para uma análise compreensiva do efeito da topologia de montagem e da sazonalidade sobre a previsibilidade (comparação fixo *versus* rastreador), culminando em um posicionamento crítico sobre o estado da arte em modelagem preditiva (clássico *versus* LLM). Os três eixos compartilham a mesma base experimental – a planta *twin-plant* no cerrado brasileiro – e, juntos, constituem uma investigação coerente sobre os fatores que determinam a previsibilidade da geração fotovoltaica em sistemas reais.

1.3 OBJETIVOS

1.3.1 Objetivo Geral

Investigar, a partir de uma planta fotovoltaica em configuração *Twin-Plant*, como a topologia de montagem (estrutura fixa *versus* rastreamento solar de eixo único) e a sazonalidade meteorológica influenciam a previsibilidade de curto prazo da geração de potência ativa, e avaliar comparativamente o desempenho de algoritmos clássicos de aprendizado de máquina frente a modelos emergentes baseados em *Large Language Models* nesse contexto.

1.3.2 Objetivos Específicos

Para alcançar o objetivo geral, foram estabelecidos os seguintes objetivos específicos:

- a) projetar, implementar e documentar uma arquitetura de aquisição de dados industrial capaz de sincronizar, em alta resolução temporal, medições elétricas em nível de inversor e variáveis meteorológicas provenientes de uma estação solarimétrica;
- b) consolidar e caracterizar estatisticamente o *dataset* BST-PV, disponibilizando-o publicamente como contribuição à comunidade científica;
- c) estabelecer um pipeline reproduzível de pré-processamento orientado por fundamentos físicos, capaz de tratar valores ausentes preservando a consistência física das séries temporais de geração fotovoltaica;
- d) desenvolver e validar uma estratégia de engenharia de atributos temporais baseada em defasagens informadas por análise de autocorrelação e correlação cruzada;

- e) comparar sistematicamente o desempenho preditivo entre os subsistemas fixo e com rastreamento solar, ao longo das quatro estações do ano, isolando o efeito da topologia de montagem;
- f) avaliar comparativamente modelos clássicos de aprendizado de máquina (*Random Forest*, XGBoost e LightGBM) e modelos baseados em LLM (Time-LLM, Chronos e Prophet) na previsão de potência fotovoltaica, em diferentes resoluções temporais;
- g) discutir as implicações práticas dos resultados obtidos para a seleção de modelos de previsão em aplicações reais de monitoramento, despacho e controle de plantas fotovoltaicas.

1.4 CONTRIBUIÇÕES

As principais contribuições desta dissertação podem ser sintetizadas como segue:

- a) a introdução do *dataset* BST-PV, um conjunto de dados inédito e de alta resolução que viabiliza a comparação controlada entre tecnologias de montagem fotovoltaica sob condições meteorológicas idênticas, disponibilizado publicamente para a comunidade científica;
- b) a proposição de um pipeline de pré-processamento e engenharia de atributos fisicamente informado, que combina zeragem noturna astronômica, interpolação, imputação multivariada e defasagens temporais selecionadas por critérios estatísticos (ACF/CCF) e físicos (inércia térmica de módulos);
- c) evidências empíricas sobre como a sazonalidade e a dinâmica de rastreamento solar interagem para determinar a dificuldade de previsão de curto prazo, mostrando que a maior complexidade preditiva do sistema com rastreamento não é uniforme ao longo do ano;
- d) uma avaliação crítica e comparativa entre modelos clássicos de aprendizado de máquina e modelos emergentes baseados em LLM para previsão fotovoltaica, evidenciando, com dados reais de operação, as limitações estruturais dessas arquiteturas emergentes nesse domínio específico.

1.5 ORGANIZAÇÃO DO TEXTO

Esta dissertação está organizada em cinco capítulos, além deste introdutório. O Capítulo 2 apresenta a revisão da literatura, abordando os principais *datasets* fotovoltaicos disponíveis na literatura, as abordagens de aprendizado de máquina e aprendizado profundo aplicadas à previsão de geração solar, e o estado da arte em modelos baseados em LLM para séries temporais. O Capítulo 3 descreve a metodologia adotada, incluindo a caracterização

da planta *Twin-Plant* e da arquitetura de aquisição de dados, o *dataset* BST-PV, o pipeline de pré-processamento e engenharia de atributos, e os modelos de previsão avaliados. O Capítulo 4 apresenta e discute os resultados obtidos nas três etapas da pesquisa: a caracterização do *dataset* e o *benchmark* inicial, a análise sazonal comparativa entre os subsistemas fixo e com rastreamento, e a comparação entre modelos clássicos e baseados em LLM. Por fim, o Capítulo 5 apresenta as conclusões gerais do trabalho, suas limitações e perspectivas de pesquisas futuras.

2 REVISÃO DA LITERATURA

Este capítulo apresenta o estado da arte nos temas que fundamentam a presente dissertação, organizado em três eixos complementares. A Seção 2.1 discute os principais conjuntos de dados fotovoltaicos e meteorológicos disponíveis na literatura, contextualizando as lacunas que motivaram a criação do *dataset* BST-PV. A Seção 2.2 revisa as abordagens de aprendizado de máquina e aprendizado profundo aplicadas à previsão de geração solar fotovoltaica de curto prazo, com ênfase em modelos de *ensemble* e arquiteturas baseadas em redes recorrentes. Por fim, a Seção 2.3 apresenta o estado da arte em modelos de linguagem de grande escala (*Large Language Models* — LLMs) adaptados para previsão de séries temporais, discutindo suas potencialidades e limitações no contexto fotovoltaico.

2.1 CONJUNTOS DE DADOS PARA PESQUISA FOTOVOLTAICA

A disponibilidade de conjuntos de dados de alta qualidade é condição fundamental para o desenvolvimento, treinamento e avaliação de modelos preditivos em sistemas fotovoltaicos. Revisões sistemáticas recentes (8, 9, 10) ressaltam que o desempenho dos modelos de aprendizado de máquina é fortemente condicionado pela qualidade e representatividade dos dados utilizados no treinamento. Nesse contexto, Yao et al. (11) argumentam que conjuntos de dados que combinem simultaneamente medições de geração elétrica e variáveis meteorológicas são excepcionalmente escassos, constituindo uma lacuna relevante na literatura.

2.1.1 Categorias de Dados Fotovoltaicos

Os dados utilizados em pesquisa de energia fotovoltaica podem ser classificados em quatro categorias principais (11). A primeira consiste em medições de superfície (*ground-based*), obtidas diretamente no local de interesse por meio de instrumentação de alta precisão, como pirômetros e sensores de temperatura. Embora ofereçam alta acurácia e sejam essenciais para validação de modelos físicos, essas estações são custosas e esparsamente distribuídas geograficamente (12, 13).

A segunda categoria compreende dados derivados de satélite, que oferecem cobertura global e estão disponíveis para um grande número de localidades. Embora historicamente menos precisos do que as medições de superfície, avanços recentes têm melhorado sua confiabilidade (14). A terceira categoria engloba dados de modelos dinâmicos de tempo (*Numerical Weather Prediction* — NWP), que podem fornecer amplo conjunto de variáveis atmosféricas com resoluções espaciais e temporais crescentes, ainda que com acurácia inferior às medições *ground-based* (15).

Por fim, a quarta categoria reúne dados de sistemas fotovoltaicos, que incluem medições de geração elétrica e metadados do sistema. Isoladamente, esses dados têm valor analítico limitado, uma vez que a geração fotovoltaica é fortemente condicionada pelas condições ambientais; a combinação com dados meteorológicos alinhados temporalmente é, portanto, essencial tanto para previsão quanto para análise de desempenho (11).

2.1.2 Conjuntos de Dados Relevantes na Literatura

Os esforços de disponibilização de dados para pesquisa fotovoltaica podem ser divididos em iniciativas de escopo local ou regional — com alta resolução temporal e foco em *benchmarking* de modelos físicos — e iniciativas de escala global, voltadas à caracterização geoespacial de recursos solares.

Entre os conjuntos de dados de referência histórica, destaca-se o *National Solar Radiation Data Base* (NSRDB) (14), que provê irradiância solar e dados meteorológicos com resolução espacial de 4 km e intervalo de 30 minutos sobre os Estados Unidos e regiões adjacentes, abrangendo o período de 1998 a 2016. Para *benchmarking* físico em alta resolução temporal, o conjunto de dados de Folsom, Califórnia (12) integra medições de irradiância *ground-based*, imagens de câmeras de céu, previsões NWP e múltiplas linhas de base, tornando-se referência para o desenvolvimento de métodos de previsão intra-horária. De forma complementar, os dados do arranjo NIST (*National Institute of Standards and Technology*) (13) fornecem medições elétricas e meteorológicas com resolução de 1 segundo para múltiplas configurações de sistemas PV no estado de Maryland.

Iniciativas mais recentes têm ampliado o escopo geográfico e a diversidade das fontes. O *SolarCube* (4) integra imagens de satélite com observações *in situ* para facilitar tarefas de previsão em escala global e diversas zonas climáticas. Complementarmente, inventários geoespaciais como o conjunto harmonizado de sistemas fotovoltaicos instalados nos EUA (5) e o mapa global de painéis PV com resolução de 20 metros (16) fornecem metadados críticos sobre configurações, tipos de montagem e crescimento espaço-temporal da capacidade instalada.

No contexto de sistemas residenciais de alta frequência, o conjunto de dados da Estônia (17), com resolução de 10 segundos, captura flutuações rápidas de geração e consumo, sendo particularmente relevante para estudos de integração com a rede em escala residencial. No domínio de degradação de sistemas PV, Chen et al. (18) apresentam uma revisão extensa dos conjuntos de dados disponíveis para estudos de confiabilidade e modelagem de desempenho ao longo do tempo.

No contexto brasileiro e de economias emergentes, Yao et al. (11) disponibilizaram um conjunto de dados de geração PV para dez sistemas localizados na China, acompanhado de metadados, dados de previsão numérica do tempo e medições locais. Essa iniciativa representa um avanço relevante, ainda que limitada à cobertura de um único país.

A Tabela 1 sintetiza as principais características dos conjuntos de dados mencionados, permitindo uma comparação direta de escopo, resolução e tipo de dado disponível, e inclui, na última linha, o *dataset* BST-PV proposto nesta dissertação, posicionado para evidenciar, por contraste direto, a combinação de características que o diferencia dos demais conjuntos listados.

Tabela 1 – Comparativo de conjuntos de dados fotovoltaicos e meteorológicos representativos da literatura.

Referência	Escopo / Local	Resolução	Características Principais
Li et al. (4)	Global (<i>benchmark</i>)	15 min	Satélite + <i>ground-based</i> ; irradiância derivada de física
Sengupta et al. (14)	EUA + adjacências	30 min	Irradiância e meteorologia em superfície/satélite
Stid et al. (5)	EUA (contíguos)	Polígonos geoesp.	Metadados de sistemas; tipo de montagem; capacidade
Li et al. (16)	Cobertura global	20 m espacial	Mapas anuais de painéis PV (2019–2022)
Yao et al. (11)	Hebei, China	15 min	Irradiância, geração PV, variáveis meteorológicas
Hasan et al. (17)	Estônia (residencial)	10 s	Geração PV, carga, tensão e corrente por fase
Pedro et al. (12)	Califórnia, EUA	1 min / intra-h	GHI, DNI, imagens de céu, NWP, <i>baselines</i>
Boyd (13)	Maryland, EUA (NIST)	1 s / 1 min	Meteorológico, elétrico, múltiplas configurações
BST-PV (Rodrigues et al. (19), este trabalho)	Cerrado, Brasil	5 min	Elétrico em nível de inversor; meteorológico <i>ground-truth</i> ; configuração <i>twin-plant</i> (fixo + rastreador)

Fonte: Adaptado dos trabalhos citados.

2.1.3 Lacunas Identificadas e Motivação para o BST-PV

Apesar dos avanços descritos, importantes limitações persistem na literatura. Em primeiro lugar, a maioria dos conjuntos de dados disponíveis recorre à irradiância estimada por satélite ou a medições agregadas no nível da planta, o que não captura adequadamente flutuações de alta frequência causadas por transientes de nuvens — críticos para a previsão intra-horária (12). Em segundo lugar, poucos conjuntos de dados fornecem medições elétricas detalhadas no nível do inversor ou da *string*, limitando sua aplicabilidade para monitoramento de desempenho, detecção de falhas e análise de degradação (18).

Em terceiro lugar, e de forma particularmente relevante para o escopo desta dissertação, há ausência de conjuntos de dados que permitam comparação direta entre diferentes tecnologias de montagem — sistemas fixos e sistemas com rastreamento solar — sob condições meteorológicas idênticas. Sem essa característica, torna-se impossível isolar com precisão os efeitos dos algoritmos de rastreamento (como a estratégia de *backtracking*)

da variabilidade puramente atmosférica, tanto no comportamento de geração quanto no desempenho de modelos preditivos treinados sobre esses dados (19).

Nesse contexto, o *dataset* BST-PV (*Brazilian Savanna Twin-PV*), introduzido nesta dissertação, visa suprir essas lacunas ao combinar, de forma inédita: (i) medições elétricas sincronizadas no nível do inversor; (ii) variáveis meteorológicas de alta frequência obtidas de estação solarimétrica instalada no local; e (iii) uma configuração controlada de *twin-plant*, com subsistemas de estrutura fixa e rastreamento solar operando sob condições ambientais idênticas. Até onde é do conhecimento dos autores, nenhum conjunto de dados publicamente disponível satisfaz simultaneamente essas três condições.

2.2 PREVISÃO DE GERAÇÃO FOTOVOLTAICA COM APRENDIZADO DE MÁQUINA

A previsão de geração fotovoltaica de curto prazo é um problema de regressão em séries temporais multivariadas que tem atraído crescente atenção na literatura de aprendizado de máquina aplicado a sistemas de energia (20, 8, 21). Revisões abrangentes (9, 10) documentam o rápido avanço das técnicas empregadas, que evoluíram de abordagens estatísticas clássicas para arquiteturas de aprendizado profundo cada vez mais sofisticadas.

2.2.1 Abordagens Iniciais e Métodos Clássicos

As primeiras aplicações de inteligência artificial à previsão fotovoltaica basearam-se em redes neurais de função de base radial (RBF) para modelar a produção diária de energia a partir de variáveis atmosféricas como nebulosidade e horas de sol (22). Sistemas de inferência neuro-fuzzy adaptativos (ANFIS) também demonstraram alta acurácia para previsões mensais de radiação solar, com erros quadráticos médios normalizados tão baixos quanto 0,22% (23).

Embora eficazes para dados de baixa resolução temporal, esses métodos demonstraram limitações na captura das dinâmicas de alta frequência características de sistemas modernos de geração solar, motivando a adoção de técnicas mais expressivas.

2.2.2 Modelos de Ensemble para Previsão Fotovoltaica

Métodos de *ensemble* baseados em árvores de decisão constituem atualmente uma das abordagens mais robustas e amplamente utilizadas para previsão fotovoltaica de curto prazo, em virtude da capacidade de modelar relações não lineares entre variáveis meteorológicas e geração de energia com custo computacional relativamente baixo (20, 24).

O *Random Forest* (RF) é um método de *bagging* que reduz a variância por meio da agregação de múltiplas árvores de decisão. Sua robustez a overfitting e a facilidade de interpretação dos atributos mais relevantes o tornam especialmente adequado para

problemas com muitas variáveis de entrada, como é o caso da previsão fotovoltaica multivariada (25). O XGBoost (*Extreme Gradient Boosting*) e o LightGBM (*Light Gradient Boosting Machine*) são métodos de *boosting* que constroem sequencialmente árvores para corrigir erros residuais dos modelos anteriores, alcançando frequentemente desempenho preditivo superior ao RF em problemas tabulares de regressão (26, 27).

A otimização de hiperparâmetros exerce papel significativo no desempenho desses modelos. Estratégias como *Grid Search* e *Random Search* têm sido substituídas por abordagens bayesianas, como a biblioteca Optuna com o algoritmo TPE (*Tree-structured Parzen Estimator*), que constroem modelos probabilísticos do espaço de hiperparâmetros e selecionam iterativamente configurações com maior probabilidade de melhoria (28). Essa estratégia demonstrou vantagens expressivas em termos de eficiência computacional e qualidade dos resultados em comparação com buscas exaustivas.

2.2.3 Engenharia de Atributos Temporais

A formulação do problema de previsão fotovoltaica como regressão supervisionada em séries temporais exige atenção especial à construção dos atributos de entrada (*features*). A abordagem de janela deslizante (*sliding window*), na qual um número fixo de observações passadas é utilizado como entrada para prever um passo futuro, é frequentemente empregada como *baseline* por sua simplicidade e baixo custo computacional (29).

No entanto, a literatura indica que a incorporação de defasagens temporais (*lag features*) selecionadas por análise estatística pode resultar em ganhos expressivos de desempenho (30, 31). A função de autocorrelação (ACF) da série de potência fotovoltaica tipicamente revela autocorrelação significativa por aproximadamente 30 a 40 passos (equivalentes a 2,5–3,3 horas em resolução de 5 minutos) e picos periódicos nos passos 144 e 288, correspondentes a 12 e 24 horas, associados ao ciclo solar diário (32, 33). Defasagens selecionadas nessas escalas — finas (1 a 12 passos), intermediárias (24 a 48 passos) e periódicas (144 e 288 passos) — permitem ao modelo capturar dinâmicas em múltiplas escalas temporais, desde variações de minutos até a recorrência diária do padrão solar.

Para as variáveis meteorológicas, a função de correlação cruzada (CCF) entre cada preditor e a variável alvo orienta a definição de defasagens distintas por variável. A irradiância (POA, GHI e GRI) tipicamente apresenta pico de correlação próximo a defasagem zero, refletindo seu efeito praticamente instantâneo sobre a potência, ao passo que a temperatura do painel exibe pico deslocado para defasagens negativas, evidenciando um atraso térmico fisicamente esperado, da ordem de 5 a 10 minutos (34). A inclusão de estatísticas móveis (média e desvio padrão) sobre janelas de curto prazo, bem como a codificação cíclica de variáveis temporais (hora do dia e mês do ano) por funções senoidais e cossenoidais, complementam o conjunto de atributos e ampliam a capacidade do modelo de capturar tendências e sazonalidades (35, 30).

2.2.4 Redes Neurais Profundas e Arquiteturas Híbridas

O crescimento da capacidade computacional e a disponibilidade de dados em alta resolução impulsionaram a adoção de arquiteturas de aprendizado profundo para previsão fotovoltaica. Redes *Long Short-Term Memory* (LSTM) e suas variantes bidirecionais (BiLSTM) demonstraram capacidade superior na modelagem de dependências temporais de longo alcance em comparação com redes recorrentes tradicionais (3, 36).

Modelos híbridos que combinam múltiplos mecanismos têm produzido resultados consistentemente superiores a arquiteturas isoladas. A integração de Redes Neurais Convolucionais (CNN) com BiLSTM e mecanismos de atenção permite extrair características multidimensionais dos dados meteorológicos e capturar padrões sequenciais em diferentes escalas (37). Arquiteturas que incorporam Redes Convolucionais Temporais (TCN) com módulos de atenção eficiente de canal (ECANet) demonstraram eficácia na captura de dependências espacio-temporais em dados de resolução de 5 minutos (38).

Para mitigar a escassez de dados em aplicações específicas, como sistemas *behind-the-meter*, o aprendizado por transferência aplicado a modelos LSTM com atenção tem demonstrado redução significativa no tempo de treinamento sem perda de desempenho preditivo (39, 40).

O pré-processamento de sinais via Transformada *Wavelet* (WT) tem sido frequentemente adotado como etapa preparatória para redes neurais, especialmente em sistemas com rastreamento solar ativo. A combinação de WT com sistemas neuro-fuzzy (41) ou com redes LSTM (42) permite previsão ultracurta com controle em tempo real da posição dos rastreadores. A decomposição do sinal de potência em coeficientes de detalhe e aproximação facilita a identificação de padrões de múltiplas escalas, reduzindo o impacto do ruído inerente às medições de alta frequência (36).

Redes neurais artificiais (ANN) com otimizador Adam e escalonamento dinâmico da taxa de aprendizado estabeleceram correlações não lineares robustas entre entradas meteorológicas e geração para sistemas tanto fixos quanto com rastreamento de eixo único (43). Algoritmos de otimização meta-heurísticos híbridos, como a combinação de Algoritmos Genéticos (GA) com Evolução Diferencial Multi-Objetivo Adaptativa (GA-AMODE), também têm sido empregados para ajustar hiperparâmetros de redes BiLSTM, equilibrando busca global e local para maior acurácia de previsão (3).

A integração de Previsão Numérica do Tempo (NWP) em modelos de aprendizado profundo representa outra linha ativa de pesquisa. Chen et al. (15) avaliaram cinco estratégias distintas de fusão de NWP em redes profundas e demonstraram que métodos específicos de integração podem reduzir erros de previsão de longo prazo em até 62,4% em comparação com *baselines* sem NWP.

2.2.5 Sazonalidade e Topologia de Montagem como Fatores de Previsibilidade

A influência da sazonalidade sobre a acurácia dos modelos de previsão fotovoltaica é documentada na literatura, embora raramente quantificada de forma sistemática e controlada (21). Em geral, condições atmosféricas mais estáveis, como as predominantes no inverno em regiões de clima tropical de savana, resultam em séries temporais mais suaves e, portanto, mais previsíveis. Em contrapartida, o verão é caracterizado por alta variabilidade e ocorrência frequente de sombreamento intermitente por nuvens convectivas, aumentando significativamente a incerteza do processo de geração (8).

A topologia de montagem — em particular a distinção entre sistemas de estrutura fixa e sistemas com rastreamento solar — representa uma dimensão adicional de complexidade que é frequentemente negligenciada na literatura. Sistemas com rastreamento de eixo único introduzem dinâmicas associadas ao movimento dos módulos, que alteram continuamente a geometria de incidência da radiação solar. Isso resulta em um perfil de irradiância no plano do módulo (POA) mais sensível a variações rápidas de nebulosidade, amplificando flutuações de curto prazo e tornando a série temporal de geração mais irregular (44, 45). Adicionalmente, a estratégia de *backtracking* — que limita o ângulo de rastreamento para evitar sombreamento entre fileiras — introduz não linearidades e dependências geométricas que raramente são modeladas explicitamente nos algoritmos preditivos.

Estudos recentes sobre o desempenho comparativo de sistemas fixos e com rastreamento apontam ganhos de produção de energia da ordem de 21% para rastreamento de eixo único e 23,5% para rastreamento de dois eixos em relação a sistemas fixos, conforme reportado para condições australianas (46). Em regiões equatoriais, aumentos de até 19,62% na produção com rastreamento de dois eixos foram documentados (47). Contudo, a maior produção de energia não implica necessariamente maior previsibilidade: a dinâmica adicional introduzida pelo rastreamento pode aumentar a complexidade da tarefa preditiva, especialmente em períodos de alta variabilidade atmosférica.

Essa interação entre sazonalidade e topologia de montagem — e seu impacto sobre a previsibilidade — constitui uma das questões centrais investigadas nesta dissertação, e sua análise controlada é viabilizada pela configuração *twin-plant* do complexo experimental utilizado.

2.3 MODELOS BASEADOS EM *LARGE LANGUAGE MODELS* PARA SÉRIES TEMPORAIS

O sucesso dos *Large Language Models* (LLMs) em tarefas de processamento de linguagem natural tem motivado investigações crescentes sobre sua aplicabilidade em domínios não linguísticos, incluindo a previsão de séries temporais (48). Essa linha

de pesquisa parte da hipótese de que as capacidades de generalização, aprendizado de representações e raciocínio em contextos longos — que distinguem os LLMs em tarefas de linguagem — podem ser reaproveitadas para modelar padrões temporais em dados numéricos (49).

2.3.1 Arquiteturas LLM para Previsão de Séries Temporais

Diversas arquiteturas têm sido propostas para adaptar LLMs à previsão de séries temporais. O LLMTIME (50) utiliza GPT-3 e LLaMA-2 para previsão *zero-shot* por reformulação de séries numéricas como sequências de texto, explorando a capacidade de generalização dos modelos sem ajuste fino no domínio alvo. O Time-LLM (6) reprograma o GPT-2 para previsão multivariada por meio de segmentação em *patches* sobrepostos e ajuste fino seletivo restrito às camadas de embedding, mantendo o *backbone* congelado. Essa abordagem busca reduzir o custo computacional do ajuste fino preservando o conhecimento prévio do modelo.

O PromptCast (51) emprega modelos BART e BERT com foco em engenharia de *prompts*, sem modificar os pesos do modelo base, o que representa uma alternativa de baixo custo computacional. O Chronos (7) combina arquiteturas GPT-2 e T5, convertendo dados numéricos em *tokens* de linguagem por meio de quantização e operando em modo *zero-shot*, sem qualquer ajuste ao conjunto de dados alvo. Por sua capacidade de generalização sem treinamento específico no domínio, o Chronos tem despertado interesse particular em cenários com escassez de dados históricos (7).

O Prophet (52) não é, tecnicamente, um *Large Language Model*: trata-se de um *framework* de decomposição aditiva/multiplicativa que modela tendência, sazonalidade e efeitos de feriados, permitindo a incorporação de regressores exógenos. Nesta dissertação, o Prophet é tratado como um modelo de previsão alternativo emergente, avaliado em conjunto com Chronos e Time-LLM por representar, junto a eles, uma abordagem amplamente adotada na prática de séries temporais que compete com os modelos baseados em *ensemble* sem depender de engenharia de atributos manual — um agrupamento funcional para fins de *benchmark*, e não uma classificação taxonômica de arquitetura. Sua configuração é relativamente simples e sua interpretabilidade é uma vantagem em contextos empresariais, embora a rigidez da decomposição sazonal possa ser uma limitação em séries com não-estacionariedades locais pronunciadas.

No contexto fotovoltaico especificamente, Zhang et al. (53) propõem um modelo probabilístico baseado em LLM com transformadas *wavelet* para previsão de médio prazo, enquanto Hu et al. (54) integram variáveis exógenas e mecanismos de atenção aprimorados para extração de padrões em séries energéticas.

2.3.2 Limitações dos LLMs em Previsão Fotovoltaica

A aplicação de LLMs à previsão de séries temporais numéricas impõe desafios específicos relacionados à representação, tokenização e integração de covariáveis exógenas (55). No contexto fotovoltaico, onde a alta variabilidade, a dependência meteorológica e as dinâmicas não estacionárias são características intrínsecas, essas limitações tornam-se particularmente relevantes.

O Chronos, por exemplo, opera exclusivamente sobre o histórico da série alvo e não suporta nenhuma forma de covariável exógena. Em cenários com instrumentação meteorológica disponível — como o estudado nesta dissertação — isso impõe um teto de acurácia intransponível, uma vez que o modelo é forçado a inferir variações de geração a partir de informações endógenas, ignorando sinais físicos diretamente causais como irradiância e temperatura do módulo. O Time-LLM, embora multivariado, tem seu desempenho fortemente condicionado ao valor do comprimento de contexto (*seq_len*): janelas inadequadas impedem a captura de periodicidades diárias da série fotovoltaica, e falhas de paridade durante a inferência podem resultar em previsões não-nulas para instantes noturnos — exigindo pós-processamento corretivo em aplicações operacionais. O Prophet é estruturalmente penalizado pela imposição de componentes sazonais rígidos sobre séries com não-estacionariedades locais, como as induzidas por sombreamento intermitente e pelas dinâmicas de *ramp-up* e *ramp-down* características de sistemas com rastreamento solar (56).

Uma hipótese frequente é que a capacidade dos LLMs de modelar dependências de longo alcance via mecanismos de atenção conferiria vantagem sobre algoritmos clássicos de aprendizado de máquina. Entretanto, na presença de covariáveis meteorológicas de alta qualidade, a relação irradiância-potência é fisicamente determinista em condições de céu limpo e suficientemente capturável por regressores não lineares locais — como métodos de *ensemble* baseados em árvores — sem que se demande o custo computacional e de infraestrutura associado às arquiteturas de LLM (56).

2.3.3 Posicionamento dos LLMs no Estado da Arte

O posicionamento dos modelos baseados em LLM frente ao estado da arte em previsão fotovoltaica permanece uma questão em aberto na literatura. A ausência de comparações sistemáticas entre LLMs e algoritmos clássicos de ML em condições equivalentes — mesma base de dados, mesma partição temporal, mesmo conjunto de covariáveis — limita a compreensão real das vantagens e limitações dessas arquiteturas nesse domínio específico (56).

Evidências empíricas disponíveis sugerem que, em cenários com dados históricos suficientes e covariáveis meteorológicas de alta qualidade, os modelos de *ensemble* (Random Forest, XGBoost, LightGBM) mantêm vantagem competitiva expressiva sobre as

abordagens baseadas em LLM tanto em acurácia quanto em eficiência computacional (56). Esse cenário pode mudar em contextos de previsão multi-passo de longo alcance, dados escassos, ou ausência de covariáveis, onde a capacidade de generalização *zero-shot* dos LLMs pode oferecer vantagem real.

Trabalhos futuros que explorem o ajuste fino (*fine-tuning*) de *foundation models* com dados fotovoltaicos específicos, bem como a integração de NWP como regressores exógenos em arquiteturas LLM, representam direções promissoras para estreitar a lacuna de desempenho identificada (56).

2.4 SÍNTESE E POSICIONAMENTO DESTA DISSERTAÇÃO

A revisão apresentada neste capítulo evidencia três lacunas inter-relacionadas na literatura que esta dissertação busca endereçar de forma integrada.

Primeiramente, no plano dos dados, a ausência de conjuntos de dados abertos que combinem medições elétricas em nível de inversor, variáveis meteorológicas de alta frequência e uma configuração controlada de *twin-plant* limita tanto o desenvolvimento quanto a validação de modelos preditivos para sistemas com diferentes tecnologias de montagem. O *dataset* BST-PV, introduzido nesta dissertação, preenche essa lacuna ao disponibilizar publicamente dados de alta resolução (5 minutos, 343 dias, aproximadamente 2,16 milhões de registros) de uma planta fotovoltaica real no cerrado brasileiro, com subsistemas fixo e com rastreamento solar.

Em segundo lugar, no plano metodológico, a interação entre sazonalidade e topologia de montagem como determinantes da previsibilidade fotovoltaica raramente é investigada de forma controlada na literatura. A configuração *twin-plant* adotada nesta dissertação permite isolar, sob condições meteorológicas idênticas, o efeito da arquitetura de montagem sobre a complexidade da série temporal de geração e sobre o desempenho dos modelos preditivos ao longo das quatro estações do ano.

Em terceiro lugar, no plano da avaliação de modelos, a comparação sistemática entre algoritmos clássicos de aprendizado de máquina e modelos emergentes baseados em LLM para previsão fotovoltaica em condições equivalentes e com dados reais de operação ainda é escassa na literatura. Esta dissertação contribui com evidências empíricas sobre esse posicionamento, discutindo as implicações práticas para a seleção de modelos em aplicações reais de monitoramento e despacho de energia solar.

O Capítulo 3 descreve em detalhe a metodologia adotada para abordar essas três dimensões, incluindo a arquitetura de aquisição de dados, a caracterização do *dataset* BST-PV, o pipeline de pré-processamento e a estratégia de modelagem adotada nas três etapas da pesquisa.

3 MATERIAIS E MÉTODOS

Este capítulo descreve os materiais e os procedimentos metodológicos que fundamentam a pesquisa. A Seção 3.1 apresenta o sistema fotovoltaico experimental utilizado como base de coleta de dados, incluindo as especificações técnicas dos subsistemas fixo e com rastreamento, a infraestrutura de instrumentação meteorológica e a arquitetura de aquisição de dados. A Seção 3.2 caracteriza o *dataset* BST-PV, descrevendo seu volume, cobertura temporal, variáveis disponíveis e qualidade dos dados. A Seção 3.3 detalha o pipeline de pré-processamento compartilhado pelos três estudos experimentais. Por fim, as Seções 3.4, 3.5 e 3.6 descrevem, respectivamente, os três desenhos experimentais progressivos que compõem a estratégia de investigação desta dissertação.

3.1 SISTEMA FOTOVOLTAICO EXPERIMENTAL

3.1.1 Caracterização do Sítio e Clima

O conjunto de dados utilizado nesta dissertação foi coletado de uma usina fotovoltaica de escala utilitária localizada na região do Cerrado brasileiro, a uma altitude de 927 m. O local é caracterizado por um clima tropical de savana (classificação Köppen Aw), com alta incidência de irradiância solar e estações bem definidas de chuva e seca, o que confere condições meteorologicamente diversas e representativas para a avaliação de modelos de previsão ao longo do ciclo anual.

A planta foi concebida como arranjo experimental comparativo, denominado configuração *Twin-Plant*: dois subarrays adjacentes que compartilham os mesmos componentes elétricos (módulos fotovoltaicos e inversores), diferindo exclusivamente na tecnologia de montagem — um sistema de estrutura fixa e um sistema com rastreamento solar de eixo único. Essa configuração viabiliza comparações controladas entre as tecnologias sob condições ambientais idênticas, sendo particularmente adequada para avaliação de desempenho e desenvolvimento de modelos preditivos.

3.1.2 Especificações Técnicas dos Subsistemas

A capacidade instalada total da usina é de 3 MW_{AC} (aproximadamente 3,9 MW_p em corrente contínua). Ambos os subsistemas utilizam módulos fotovoltaicos bifaciais monocristalinos (Risen RSM110-8-540BMDG, 540 W_p) e inversores *string* (Sungrow SG125-HV, 125 kW). A Tabela 2 resume as principais características técnicas de cada subsistema.

Tabela 2 – Especificações técnicas dos sistemas fotovoltaicos gêmeos.

Parâmetro	Sistema Fixo	Sistema com Rastreamento
Capacidade (AC)	1000 kW	2000 kW
Capacidade (DC)	1,30 MW _p	2,60 MW _p
Tecnologia do módulo	Bifacial monocristalino	Bifacial monocristalino
Modelo do módulo	Risen RSM110-8-540BMDG	Risen RSM110-8-540BMDG
Fator de bifacialidade	70% $\pm$ 5	70% $\pm$ 5
Modelo do inversor	Sungrow SG125-HV	Sungrow SG125-HV
Tipo de montagem	Estrutura fixa	Rastreador horizontal de eixo único
Azimute	20°	0° (eixo N-S)
Taxa de cobertura do solo (GCR)	53,20%	39,70%
Espaçamento entre fileiras	9,00 m	6,00 m
Faixa de rastreamento / <i>backtracking</i>	N/A	$\pm 55^\circ$ / Sim
Altura do eixo	1,50 m	1,60 m

Fonte: Adaptado de Rodrigues et al. (19).

3.1.2.1 Sistema de Estrutura Fixa (Planta A)

O subsistema de estrutura fixa possui capacidade instalada de 1000 kW_{AC} e aproximadamente 1,30 MW_p em corrente contínua, composto por 2.405 módulos bifaciais de 540 W_p. O arranjo é configurado em 65 *strings* com 37 módulos em série, distribuídas entre oito inversores Sungrow SG125-HV. Os módulos são montados em estrutura fixa com inclinação otimizada para a latitude local e azimute de 20° a leste do norte, com Taxa de Cobertura do Solo (GCR) de 53,2% e espaçamento entre fileiras de 9,0 m.

3.1.2.2 Sistema com Rastreamento Solar de Eixo Único (Planta B)

O subsistema de rastreamento possui capacidade instalada de 2000 kW_{AC} e aproximadamente 2,60 MW_p em corrente contínua, dividido em dois subarrays idênticos, cada um com 2.405 módulos e a mesma configuração elétrica do sistema fixo (65 *strings* com 37 módulos em série). Cada subarray é conectado a oito inversores *string*, totalizando 16 inversores e 2 MW_{AC}. Os módulos são montados em rastreadores horizontais de eixo único orientados na direção Norte-Sul (azimute 0°), com faixa de rastreamento de $\pm 55^\circ$ e *backtracking* habilitado. A Figura 1 apresenta uma vista aérea representativa da estrutura de rastreamento instalada no complexo.

A principal distinção operacional entre os subsistemas reside na estrutura de montagem: enquanto o sistema fixo mantém orientação constante, o sistema com rastreamento ajusta dinamicamente a posição dos módulos ao longo do dia, maximizando a irradiância incidente no plano do array (POA). Isso resulta em um perfil de geração com *plateau* mais pronunciado e rampas de abertura e fechamento mais abruptas, aumentando a variabilidade intradiária da potência gerada e, consequentemente, a complexidade do problema de



- Vista estrutural representativa do sistema fotovoltaico com rastreamento solar de eixo único.

Fonte: Adaptado de Rodrigues et al. (19).

previsão.


3.1.3 Arquitetura Elétrica

A arquitetura elétrica do complexo é organizada em quatro camadas funcionais hierárquicas, conforme ilustrado na Figura 2:

- (i) **Camada de campo DC:** compreende os módulos fotovoltaicos e as *strings*, responsáveis pela conversão da radiação solar em potência elétrica em corrente contínua;
- (ii) **Camada de conversão de potência:** formada pelos inversores *string*, que convertem a potência DC em AC;

- (iii) **Camada de coleção em média tensão:** inclui os três eletrocentros de 1 MW cada, onde as saídas dos inversores são agrupadas, protegidas e elevadas para 13,8 kV por meio de transformadores a seco;
- (iv) **Camada de interconexão com a rede:** composta pela infraestrutura de medição e pelo ponto de conexão com a concessionária, onde as saídas dos três blocos de geração são agregadas antes da injeção na rede de distribuição.

Um eletrocentro (Eletrocentro A) é associado ao subsistema fixo, enquanto dois eletrocentros (Eletrocentros B e C) são associados ao subsistema de rastreamento. Essa estrutura hierárquica é particularmente relevante para abordagens de modelagem em múltiplos níveis de abstração, permitindo rastreabilidade desde a geração DC até a injeção na rede.



– Arquitetura elétrica hierárquica da usina fotovoltaica *Twin-Plant*. O sistema é organizado em quatro camadas: geração DC (módulos e *strings*), conversão de potência (inversores), coleção em média tensão (eletrocentros e medição) e interconexão com a rede, na qual as saídas dos três blocos de geração são agregadas antes da injeção na rede de distribuição.

Fonte: Adaptado de Rodrigues et al. (19).

3.1.4 Instrumentação Meteorológica

A usina é equipada com uma estação solarimétrica instalada internamente ao complexo, montada em mastro de 3,2 m para minimizar efeitos de sombreamento e garantir exposição desobstruída dos sensores. A instrumentação atende às normas ISO 9060:2018 e IEC 61724-1:2021, incluindo pirômetros de alta precisão para medição de:

- Irradiância Horizontal Global (GHI — *Global Horizontal Irradiance*);
- Irradiância Horizontal Difusa (DHI — *Diffuse Horizontal Irradiance*);
- Irradiância Normal Direta (DNI — *Direct Normal Irradiance*);
- Irradiância no Plano do Array (POA — *Plane-of-Array Irradiance*);
- Irradiância refletida pelo solo (albedo/GRI — *Ground-Reflected Irradiance*), para operação bifacial.

Variáveis adicionais incluem temperatura ambiente, umidade relativa do ar, velocidade e direção do vento, temperatura na face traseira dos módulos e precipitação acumulada. Esse conjunto de variáveis permite uma caracterização abrangente e fisicamente consistente das condições ambientais que afetam o sistema fotovoltaico, sendo essencial tanto para aplicações de previsão quanto para análise de desempenho.

3.1.5 Arquitetura de Aquisição e Armazenamento de Dados

Foi implementado um sistema de aquisição de dados industrial dedicado a garantir integridade, rastreabilidade e sincronização temporal entre as medições elétricas e meteorológicas. A arquitetura, ilustrada na Figura 3, é organizada em três camadas:

Camada de borda (*edge*): baseada em um CLP WAGO CC100, no qual um motor de aquisição em Python é implantado como contêiner Docker, possibilitando operação modular e independente.

Camada de campo: os inversores fotovoltaicos comunicam via RS-485 utilizando o protocolo Modbus RTU, agrupados em conjuntos de oito unidades conectadas a *dataloggers* do fabricante. A estação solarimétrica opera com *datalogger* dedicado. Todos os *dataloggers* estão conectados a um *switch* Ethernet gerenciado, que também interliga o CLP, viabilizando a aquisição via Modbus TCP/IP.

Camada de armazenamento: um mecanismo de *polling* sincronizado garante *timestamps* consistentes em todos os dispositivos, assegurando alinhamento temporal entre as medições ambientais e elétricas. Os dados são transmitidos via API REST para um banco de dados MongoDB, cuja estrutura orientada a documentos suporta armazenamento eficiente de dados de séries temporais de alta dimensão. Um mecanismo de bufferização local no CLP permite o armazenamento temporário durante falhas de comunicação e a resincronização automática após o restabelecimento da conectividade.

3.2 O DATASET BST-PV

3.2.1 Descrição Geral

O *dataset* BST-PV (*Brazilian Savanna Twin-PV*) é um conjunto de dados fotovoltaicos multimodal composto por medições sincronizadas de geração elétrica no nível do inversor e por observações ambientais de alta resolução obtidas da estação solarimétrica instalada no local. Ao contrário da maioria dos conjuntos de dados fotovoltaicos publicamente disponíveis — que tipicamente fornecem apenas medições agregadas no nível da planta — o BST-PV captura o comportamento elétrico interno do sistema no nível do inversor, complementado por variáveis ambientais detalhadas que caracterizam o recurso solar e as condições atmosféricas.

O conjunto de dados é estruturado em três fontes sincronizadas:

- Medições elétricas dos inversores do subsistema de estrutura fixa;
- Medições elétricas dos inversores do subsistema com rastreamento solar;
- Medições meteorológicas obtidas da estação solarimétrica.

Todas as fontes são alinhadas temporalmente por meio de *timestamps* coordenados, resultando em uma série temporal multivariada unificada. O *dataset* está estruturado para facilitar a reprodutibilidade, com nomenclatura padronizada de variáveis, intervalos de amostragem consistentes e *timestamps* sincronizados, viabilizando integração direta em pipelines de aprendizado de máquina e estudos comparativos. O *dataset* está publicamente disponível em <https://www.kaggle.com/datasets/asrodrigueseng/brazilian-savanna-twin-pv-dataset-bst-pv>.

3.2.2 Volume e Cobertura Temporal

O período de cobertura do *dataset* inicia-se em 23 de janeiro de 2025 — data a partir da qual as medições meteorológicas completas, incluindo irradiância refletida pelo solo, estão disponíveis — e se estende até 31 de dezembro de 2025, totalizando 343 dias de operação contínua. A resolução temporal nativa é de 5 minutos.

A estação solarimétrica contribui com 90.721 registros, enquanto os subsistemas de estrutura fixa e de rastreamento provêm 745.909 e 1.322.923 registros, respectivamente. No total, o *dataset* compreende aproximadamente 2.160.000 observações com *timestamp* (precisamente, 2.159.555, conforme a Seção 5.1 de Rodrigues et al. (19); o resumo desse mesmo artigo arredonda esse valor para “aproximadamente 2,2 milhões”, uma diferença de arredondamento sem implicação metodológica), posicionando-o entre os maiores conjuntos de dados fotovoltaicos de acesso aberto com medições de nível de inversor e dados meteorológicos *ground-truth* simultâneos disponíveis na literatura (19).

3.2.3 Variáveis Disponíveis

O *dataset* inclui dois grupos principais de variáveis: (i) medições elétricas dos inversores, idênticas para ambos os subsistemas, e (ii) variáveis meteorológicas obtidas da estação solarimétrica. A Tabela 3 apresenta uma visão estruturada dessas variáveis.

As variáveis de inversor descrevem o comportamento elétrico do sistema fotovoltaico, incluindo potências AC e DC, grandezas elétricas trifásicas, condições de operação do MPPT (*Maximum Power Point Tracking*), produção de energia acumulada, estados operacionais e condições térmicas. Essas variáveis permitem o monitoramento detalhado de desempenho, eficiência operacional e detecção de falhas.

As variáveis meteorológicas caracterizam as condições ambientais que influenciam diretamente a geração fotovoltaica. Incluem componentes de irradiância (GHI, POA e GRI), agregados estatísticos de irradiância, temperaturas ambiente e de módulo, velocidade e direção do vento, e precipitação. Esse conjunto de variáveis é essencial para capturar a variabilidade e a intermitência do recurso solar.

3.2.4 Qualidade e Estatística dos Dados

Para garantir a qualidade dos dados, procedimentos padrão de pré-processamento foram aplicados na publicação do *dataset*, incluindo remoção de valores fisicamente inconsistentes, filtragem de medições noturnas e tratamento de dados faltantes por interpolação quando as lacunas eram inferiores a um limiar predefinido. *Outliers* associados a falhas de sensores ou falhas de comunicação foram identificados por verificações de consistência estatística e física e removidos.

As variáveis de potência exibem a maior variabilidade, variando de zero durante o período noturno a valores de pico superiores a 120 kW. Em contraste, as variáveis de tensão permanecem dentro das faixas operacionais esperadas, enquanto a frequência da rede e o fator de potência apresentam baixa dispersão, refletindo as restrições de regulação da rede.

Em termos de dados faltantes, o subsistema fixo apresenta aproximadamente 14% de ausências, enquanto o subsistema de rastreamento exibe cerca de 17%. As variáveis meteorológicas apresentam taxa de ausência de aproximadamente 8%. A uniformidade desse padrão entre variáveis de um mesmo subsistema sugere um processo sistemático e esperado de ausência, majoritariamente associado aos períodos sem geração solar, e não a falhas aleatórias de sensores.

3.3 PIPELINE DE PRÉ-PROCESSAMENTO

A previsão de geração fotovoltaica de curto prazo é formulada nesta dissertação como um problema de regressão em séries temporais multivariadas, no qual a consistência

temporal dos dados é requisito fundamental. Modelos baseados em sequências requerem séries contínuas e uniformemente amostradas para capturar adequadamente padrões temporais e suas relações com variáveis meteorológicas (24, 38). Dados reais de operação, contudo, apresentam imperfeições como amostragem irregular e valores ausentes, decorrentes de falhas de aquisição e comunicação. Para lidar com essas limitações, foi desenvolvido um pipeline de pré-processamento compartilhado pelos três estudos experimentais desta dissertação, orientado à garantia de consistência temporal, coerência física e qualidade dos dados.

A Figura 4 ilustra as etapas do pipeline. Cada etapa é descrita em detalhe a seguir.

3.3.1 Integração e Reamostragem

O pipeline inicia pela integração das medições elétricas no nível do inversor com os dados meteorológicos da estação solarimétrica. Para cada conjunto de dados de inversor, as variáveis solarimétricas correspondentes foram alinhadas e mescladas com base nos *timestamps*, resultando em uma série temporal multivariada unificada. Devido a inconsistências temporais e intervalos de amostragem irregulares inerentes aos sistemas de aquisição industriais, todos os conjuntos de dados foram reamostrados para uma resolução temporal uniforme de 5 minutos, garantindo o alinhamento temporal entre as fontes e uma base consistente para as etapas subsequentes.

3.3.2 Preenchimento Noturno por Algoritmo Astronômico

A aplicação de interpolação estatística padrão sem considerar restrições físicas pode introduzir valores irrealistas, como geração fotovoltaica não nula durante o período noturno. Para garantir consistência física, a primeira etapa de tratamento de dados ausentes emprega um algoritmo astronômico para identificar os intervalos de luz solar.

Especificamente, os horários de nascer e pôr do sol foram calculados utilizando a biblioteca Python *astral* (57), com base nas coordenadas geográficas da usina. Todos os valores ausentes de variáveis de irradiância (POA, GHI e GRI) e de potência ativa que ocorrem fora da janela de luz solar foram deterministicamente definidos como zero. Essa etapa reduz a complexidade dos procedimentos de imputação subsequentes, limitando-os aos períodos em que a geração solar é fisicamente viável.

3.3.3 Interpolação Linear para Lacunas Curtas

Após o preenchimento noturno, os valores ausentes remanescentes estão predominantemente associados a lacunas de curta duração durante o período diurno. Para tratar essas lacunas, foi empregada interpolação linear temporal, que preserva as dinâmicas temporais locais com baixa complexidade computacional.

Um limiar máximo de 50 minutos foi adotado para a interpolação, correspondendo a 10 amostras consecutivas na resolução de 5 minutos. Esse limiar representa um equilíbrio entre maximizar a recuperação de dados e garantir a confiabilidade dos valores reconstruídos. Lacunas superiores a esse limiar não foram interpoladas nessa etapa e foram encaminhadas para tratamento pela imputação multivariada KNN descrita a seguir.

3.3.4 Imputação Multivariada por KNN

Para o tratamento de lacunas de maior duração, foi utilizado o método de imputação por k -vizinhos mais próximos (KNN), que estima valores ausentes com base na similaridade entre observações no espaço de atributos. O KNN explora as correlações presentes nos dados, tornando-o adequado para séries temporais multivariadas nas quais as variáveis são frequentemente fortemente relacionadas. Dado um instante t com valor ausente, o método identifica as k observações mais similares disponíveis no conjunto de dados, segundo a distância euclidiana, e computa a média dos valores correspondentes, conforme a Equação 3.1:

$$\hat{Y}_t = \frac{1}{k} \sum_{i=1}^k Y_i \quad (3.1)$$

onde Y_i representa o valor da i -ésima observação mais próxima no espaço de atributos.

A escolha do KNN é embasada em Mantuano et al. (58), que avaliaram diversas técnicas estatísticas, de aprendizado de máquina e de aprendizado profundo para imputação em séries temporais de fontes renováveis, com taxas de ausência variando de 2% a 90%, em cenários de ausências pontuais aleatórias e de lacunas contínuas de longa duração. Os resultados indicam que o KNN alcançou consistentemente o melhor ou o segundo melhor desempenho entre os métodos avaliados, tanto em acurácia pontual (RMSE) quanto em similaridade distribucional (teste de Kolmogorov–Smirnov). Neste trabalho, adotou-se $k = 5$ e distância euclidiana como métrica de similaridade.

Cabe notar que a imputação KNN foi aplicada ao conjunto de dados completo, anteriormente à divisão em treino, validação e teste descrita na Seção 3.4.3, e não exclusivamente ao conjunto de treinamento. Essa escolha, motivada pela necessidade de reconstruir uma série temporal fisicamente contínua antes da segmentação em trechos por estação, introduz um vazamento temporal potencialmente sutil: observações do conjunto de teste podem, em princípio, ter sido usadas como vizinhos para imputar valores ausentes no conjunto de treinamento, e vice-versa. O impacto prático dessa escolha é provavelmente limitado, dado que (i) a etapa de imputação KNN trata apenas a fração residual de lacunas longas remanescentes após o preenchimento noturno e a interpolação linear (Tabela 4), tipicamente inferior a 2% das observações na variável alvo, e (ii) o KNN opera no espaço de atributos meteorológicos e elétricos, e não diretamente sobre rótulos preditivos. Ainda

assim, essa é uma limitação metodológica que deve ser reconhecida e que pode ser eliminada em trabalhos futuros por meio do ajuste dos parâmetros de imputação exclusivamente no conjunto de treinamento, replicando a prática já adotada nesta dissertação para a normalização min-max (Seção **3.4.2**).

3.3.5 Resultado do Pré-processamento e Segmentação

A Tabela 4 apresenta a evolução da redução de dados ausentes ao longo das etapas do pipeline para ambos os subsistemas. A Etapa 1 corresponde à integração e reamostagem, a Etapa 2 ao preenchimento noturno, a Etapa 3 à interpolação linear e a Etapa 4 à imputação KNN.

O preenchimento noturno reduz principalmente as ausências nas variáveis de irradiância e na variável alvo, pois a zeragem é aplicada apenas a essas variáveis. A transição da Etapa 2 para a Etapa 3 representa a maior redução global, pois a interpolação linear é aplicada a todas as variáveis, eliminando efetivamente lacunas de curta duração. Da Etapa 3 para a Etapa 4, a redução é mais moderada na variável alvo, mas permanece substancial em variáveis meteorológicas como vento, temperatura e precipitação, refletindo a eficácia da imputação KNN no tratamento de lacunas mais longas.

Após o pré-processamento, os dados foram segmentados em trechos de séries temporais contínuas e categorizados por estação do ano. Para cada estação, foram selecionados três trechos representativos por subsistema, utilizados de forma consistente nas etapas de seleção de atributos e treinamento dos modelos ao longo dos três experimentos desta dissertação.

3.4 EXPERIMENTO 1: MODELOS DE REFERÊNCIA COM JANELA DESLIZANTE

O primeiro experimento estabelece resultados de referência (*baseline*) para a previsão de geração fotovoltaica nos dois subsistemas da configuração *Twin-Plant*, utilizando um conjunto representativo de algoritmos de aprendizado de máquina e aprendizado profundo com abordagem de janela deslizante.

3.4.1 Seleção de Atributos

A seleção de atributos foi conduzida por meio do coeficiente de correlação de Pearson, calculado entre cada variável candidata e a variável alvo (`total_active_power_w`). Para evitar correlações artificialmente infladas pelos valores nulos do período noturno, a análise foi restrita ao período diurno (06h00–18h00, GMT-3). Os coeficientes foram calculados independentemente para cada um dos três trechos representativos por estação e posteriormente promediados, resultando em uma representação sazonalmente agregada da relevância de cada atributo.

Adotou-se limiar de $|r| > 0,90$ para retenção dos atributos mais correlacionados, seguindo práticas padrão de redução de dimensionalidade (24). As variáveis de irradiância apresentaram as maiores correlações com a potência ativa em ambas as configurações. Apesar do grande número de variáveis altamente correlacionadas, muitas correspondem a agregados estatísticos (mínimo, máximo e média) de uma mesma grandeza física, introduzindo redundância. Optou-se pelas versões instantâneas (`poa_irradiancia`, `ghi_irradiancia` e `gri_irradiancia`), por representarem diretamente a condição física no instante da geração e por reduzirem a multicolinearidade, preservando a interpretabilidade física das entradas do modelo.

3.4.2 Normalização

Após a seleção de atributos, foi aplicada normalização min-max para escalonar todos os atributos de entrada para o intervalo $[0, 1]$ (59). Essa transformação é fundamental para algoritmos baseados em gradiente e arquiteturas de aprendizado profundo, como a LSTM, pois garante estabilidade numérica, acelera a convergência e evita que atributos de maior magnitude (como a irradiância solar) dominem desproporcionalmente o processo de aprendizado. Para prevenir vazamento de dados (*data leakage*), os parâmetros de normalização foram ajustados exclusivamente no conjunto de treinamento e posteriormente aplicados para transformar os conjuntos de validação e teste.

3.4.3 Janela Deslizante e Particionamento

Os dados normalizados foram reformulados como um problema de aprendizado supervisionado por meio de uma abordagem de janela deslizante (*sliding window*). Nessa configuração, observações passadas da variável alvo e das covariáveis meteorológicas são utilizadas para prever o valor futuro da potência ativa. Foi adotado tamanho de janela de 10 passos (50 minutos), selecionado para enfatizar o comportamento recente do sistema — particularmente relevante para previsão de curto prazo — sem introduzir dimensionalidade excessiva que aumentaria a complexidade do modelo (29).

O conjunto de dados resultante foi particionado em subconjuntos de treinamento (70%), validação (15%) e teste (15%), seguindo uma estratégia de divisão cronológica. Essa abordagem previne o vazamento temporal de dados e garante que a avaliação do modelo reflita condições realistas de previsão (36).

3.4.4 Modelos Avaliados

Foram avaliados quatro algoritmos distintos de previsão, abrangendo desde modelos de *ensemble* baseados em árvores até uma arquitetura de aprendizado profundo amplamente adotada. A seleção visa fornecer cobertura representativa dos métodos utilizados na literatura de previsão fotovoltaica (20).

3.4.4.1 Métodos de *Ensemble*

Random Forest (RF): método de *bagging* que reduz a variância pela agregação de múltiplas árvores de decisão. Configurado com 300 árvores, profundidade máxima de 15, mínimo de 10 amostras para divisão de nó e mínimo de 5 amostras por folha.

XGBoost: método de *boosting* com 300 estimadores, profundidade máxima de 15, taxa de aprendizado de 0,05 e taxas de subamostragem de atributos e amostras de 0,8.

LightGBM (LGBM): método de *boosting* com 300 estimadores, taxa de aprendizado de 0,05, 31 folhas por árvore e taxas de subamostragem de 0,8 para amostras e atributos.

3.4.4.2 Rede Neural Recorrente

LSTM (*Long Short-Term Memory*): arquitetura com duas camadas recorrentes empilhadas, cada uma com 64 unidades ocultas, e taxa de *dropout* de 0,20 entre as camadas recorrentes para mitigar sobreajuste. A última representação oculta da sequência processada é projetada por uma camada linear para produzir a previsão de potência ativa. O treinamento foi conduzido por 30 épocas utilizando o otimizador Adam com função de perda MSE (*Mean Squared Error*).

3.4.5 Métricas de Avaliação

O desempenho preditivo dos modelos é avaliado por meio de três métricas clássicas de regressão (24):

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (3.2)$$

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (3.3)$$

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (3.4)$$

onde y_i é o valor observado, $\hat{y}_i$ é o valor predito, $\bar{y}$ é a média dos valores observados e n é o número total de amostras.

O RMSE penaliza de forma mais intensa erros de maior magnitude por meio do termo quadrático, sendo sensível a valores discrepantes. O MAE fornece uma medida direta da magnitude média dos desvios. O R^2 indica a proporção da variabilidade dos dados explicada pelo modelo. As métricas RMSE e MAE são reportadas na escala original de watts (W), permitindo interpretação direta em termos da potência do sistema.

3.5 EXPERIMENTO 2: ENGENHARIA DE ATRIBUTOS TEMPORAIS E OTIMIZAÇÃO BAYESIANA

O segundo experimento investiga o impacto da engenharia de atributos temporais (*lag features*) combinada com otimização bayesiana de hiperparâmetros sobre o desempenho preditivo dos modelos de *ensemble*, em ambos os subsistemas da configuração *Twin-Plant* ao longo das quatro estações do ano. Esse experimento estende a abordagem do Experimento 1, mantendo a mesma base de dados, o mesmo conjunto de modelos de *ensemble* e as mesmas métricas de avaliação.

3.5.1 Estratégias de Modelagem Progressivas

O pipeline experimental foi estruturado em quatro cenários progressivos, permitindo quantificar a contribuição isolada de cada componente metodológico:

- (1) **Modelo base com janela deslizante:** hiperparâmetros padrão de cada biblioteca, idêntico ao Experimento 1, utilizado como ponto de partida;
- (2) **Grid Search:** busca exaustiva de hiperparâmetros em grades predefinidas de profundidade de árvore, número de estimadores e taxa de aprendizado;
- (3) **Otimização Bayesiana (Optuna):** utilização da biblioteca Optuna com o algoritmo TPE (*Tree-structured Parzen Estimator*), que constrói um modelo probabilístico do espaço de hiperparâmetros e seleciona iterativamente configurações com maior probabilidade de melhoria (28), com eficiência superior à busca em grade;
- (4) **Atributos de defasagem (*Lag Features*) + Otimização Bayesiana:** incorporação de engenharia de atributos temporais guiada por ACF/CCF, descrita a seguir, combinada com otimização bayesiana.

3.5.2 Engenharia de Atributos por Defasagem Temporal

A principal contribuição metodológica do Experimento 2 é a construção de atributos de defasagem temporal guiada por análise estatística das funções de autocorrelação (ACF) e correlação cruzada (CCF).

3.5.2.1 Defasagens da Variável Alvo

A ACF da série de potência fotovoltaica revela autocorrelação significativa por aproximadamente 30 a 40 passos (2,5–3,3 horas em resolução de 5 minutos) e picos periódicos nítidos nos passos 144 e 288, correspondentes a 12 e 24 horas, associados ao ciclo solar diário (32, 33). Com base nessa análise, foram definidos três grupos de defasagens:

- **Defasagens finas** (passos 1 a 12, correspondendo a 5–60 minutos): para capturar a dinâmica imediata do sistema;
- **Defasagens intermediárias** (passos 24, 36 e 48, correspondendo a 2–4 horas): para o momentum de médio prazo;
- **Defasagens periódicas** (passos 144 e 288, correspondendo a 12 e 24 horas): para explorar a recorrência diária do padrão solar (32).

3.5.2.2 Defasagens das Variáveis Meteorológicas

A CCF entre cada preditor meteorológico e a variável alvo orienta a definição de defasagens distintas por variável. A irradiância (POA, GHI e GRI) apresenta pico de correlação em defasagem zero, refletindo o efeito praticamente instantâneo da irradiância sobre a potência; defasagens curtas (1 a 3 passos) foram retidas para capturar rampas de variação e transições de cobertura de nuvens (30). A temperatura do painel exibiu pico deslocado para defasagens negativas ($\text{lag} = -1$ a -2), evidenciando um atraso térmico fisicamente esperado: a inércia do painel faz com que sua temperatura responda à irradiância com retardo de 5 a 10 minutos (34), de modo que as defasagens 1 a 4 dessa variável foram incluídas como preditores.

3.5.2.3 Atributos Complementares

Foram construídas estatísticas móveis (média e desvio padrão) da variável alvo em janelas de 15, 30 e 60 minutos, representando tendência e variabilidade local da geração (30). Para evitar vazamento de informação, utilizou-se deslocamento de um passo. A hora do dia e o mês do ano foram codificados por funções senoidais e cossenoidais, preservando sua natureza cíclica (35). Por fim, foi incluído o termo de interação entre irradiância e temperatura do painel, capturando os efeitos térmicos na eficiência de conversão — uma vez que o aumento de temperatura reduz a tensão de circuito aberto e a potência gerada pelo módulo fotovoltaico (34).

3.6 EXPERIMENTO 3: MODELOS BASEADOS EM LLM E COMPARAÇÃO MULTI-ESCALA

O terceiro experimento investiga a capacidade de modelos baseados em *Large Language Models* (LLMs) de aprender e generalizar padrões em séries temporais de geração fotovoltaica, posicionando-os em relação aos algoritmos clássicos de *ensemble* avaliados nos experimentos anteriores. A avaliação é realizada simultaneamente nos dois subsistemas da configuração *Twin-Plant* e em duas resoluções temporais (5 minutos e 1 hora), permitindo identificar cenários em que cada paradigma oferece vantagem relativa.

3.6.1 Base de Dados e Particionamento

O Experimento 3 utiliza a mesma base de dados BST-PV, com o mesmo pipeline de pré-processamento descrito na Seção 3.3. Diferentemente dos Experimentos 1 e 2, que utilizam o conjunto completo de inversores de cada subsistema (745.909 registros no sistema fixo e 1.322.923 no sistema com rastreamento, conforme a Seção 3.2.2), o Experimento 3 restringe a análise a um único inversor representativo por subsistema, totalizando 98.784 registros por subsistema na resolução nativa de 5 minutos. Essa redução de escopo foi adotada para viabilizar a comparação computacionalmente custosa com os modelos baseados em LLM — em particular o ajuste fino do Time-LLM e o *rolling forecast* do Chronos — dentro de um orçamento computacional tratável, e é consistente com a prática de *benchmarking* de modelos de série temporal em um subconjunto representativo dos dados quando múltiplas arquiteturas computacionalmente intensivas são comparadas. A partição cronológica é mantida (treino/validação/teste = 70%/15%/15%, sem embaralhamento), eliminando qualquer vazamento temporal. Os quatro preditores selecionados — irradiância POA, GHI e GRI, e temperatura do painel — são utilizados como covariáveis, todos com $|r| > 0,86$ com a potência ativa em períodos diurnos. Para a resolução de 1 hora, os dados originais de 5 minutos foram reamostrados por média aritmética, preservando a energia integrada e atenuando ruídos de alta frequência.

3.6.2 Modelos Avaliados

Seis modelos foram avaliados em dois grupos:

3.6.2.1 Modelos Clássicos de *Ensemble* (grupo de referência)

Random Forest, XGBoost e LightGBM operam como regressores supervisionados diretos: dado o vetor de atributos no instante t , estimam $\hat{P}_t$ sem uso de defasagens da variável alvo, com hiperparâmetros padrão de cada biblioteca. Esse grupo constitui a linha de base competitiva, sem ajuste ao conjunto de validação.

3.6.2.2 Modelos Baseados em LLM e Abordagens Alternativas Emergentes

Esse grupo reúne Chronos e Time-LLM, modelos efetivamente baseados em arquiteturas de *Large Language Models*, e o Prophet, que tecnicamente não é um LLM, mas é avaliado junto a eles por constituir, como os dois anteriores, uma abordagem de previsão emergente que compete com os modelos de *ensemble* sem depender da engenharia de atributos manual do Experimento 2. O agrupamento é, portanto, funcional — refletindo o papel desses três modelos no *benchmark* proposto — e não uma afirmação taxonômica de que o Prophet compartilha a arquitetura dos demais.

Prophet (52): utiliza decomposição aditiva/multiplicativa com regressores exógenos (POA, GHI, GRI e temperatura do painel), padronizados por *z-score*. Os hiperpa-

râmetros `changepoint_prior_scale` e `seasonality_prior_scale` foram otimizados via Optuna (30 iterações, validação cruzada temporal, horizonte de 24 horas).

Chronos (7): *foundation model* probabilístico baseado na arquitetura T5-*small*, operando em modo *zero-shot* sem regressores exógenos, com *rolling forecast* realimentado por valores reais (*ground-truth*).

Time-LLM (6): reprograma o GPT-2 para previsão multivariada via *patches* sobrepostos (`patch_len` = 16, `stride` = 8, `seq_len` = 96), com *backbone* congelado e ajuste restrito às camadas de `PatchEmbedding` e de projeção (*early stopping*, paciência de 5 épocas).

3.6.3 Métricas e Protocolo de Avaliação

As mesmas métricas do Experimento 1 são empregadas (RMSE, MAE e R^2 , conforme Equações 3.2–3.4), reportadas na escala original (W) para as duas resoluções temporais. O RMSE é adotado como critério principal por penalizar erros de grande magnitude de forma amplificada, sendo o mais relevante para aplicações de despacho econômico e balanço de rede. O R^2 permite comparações adimensionais entre resoluções e subsistemas com variâncias distintas.


A análise de resultados contempla: (i) comparação direta entre modelos clássicos e baseados em LLM em todas as combinações subsistema $\times$ resolução; (ii) quantificação do impacto diferencial da estrutura física de montagem (fixa *vs.* rastreamento) sobre cada família de modelos; e (iii) análise qualitativa das previsões, identificando padrões de erro característicos de cada arquitetura — como a tendência do Chronos de errar transições *ramp-up/ramp-down* e do Prophet de subestimar picos no sistema com rastreamento. Cabe ressaltar que essas comparações são de natureza descritiva, baseadas em estimativas pontuais das métricas de desempenho, sem testes formais de significância estatística — uma limitação discutida na Seção 5.3 do Capítulo 5.

3.7 SÍNTESE DA ESTRATÉGIA METODOLÓGICA

A estrutura metodológica desta dissertação é organizada como uma investigação progressiva em três níveis de profundidade, conforme ilustrado na Figura 5. O Experimento 1 estabelece resultados de referência com abordagem direta (janela deslizante, hiperparâmetros padrão) para os quatro modelos avaliados, quantificando o desempenho base da previsão fotovoltaica em função da sazonalidade e da topologia de montagem. O Experimento 2 investiga o ganho obtido pela incorporação de conhecimento do domínio físico via engenharia de atributos temporais e pela otimização bayesiana de hiperparâmetros, isolando a contribuição de cada componente. O Experimento 3 posiciona os modelos baseados em LLM frente ao estado da arte em condições equivalentes, avaliando

em duas resoluções temporais e identificando as limitações arquiteturais específicas de cada abordagem.

Os três experimentos compartilham a mesma base de dados (BST-PV), o mesmo pipeline de pré-processamento e as mesmas métricas de avaliação, garantindo comparabilidade direta dos resultados. A configuração *Twin-Plant* é explorada em todos os experimentos como recurso metodológico para isolar, sob condições ambientais idênticas, o efeito da topologia de montagem sobre a complexidade da tarefa preditiva. Os resultados dos três experimentos são apresentados e discutidos de forma articulada no Capítulo 4.




– Arquitetura simplificada de aquisição de dados. Sensores meteorológicos e inversores alimentam *dataloggers* dedicados, que comunicam via Modbus a um sistema de borda baseado em CLP. Um motor em contêiner realiza *polling* sincronizado e transmite os dados a um banco MongoDB, com bufferização local para garantir persistência durante falhas de comunicação.

Fonte: Adaptado de Rodrigues et al. (19).

Tabela 3 – Variáveis do *dataset* BST-PV, agrupadas por categoria funcional. Os grupos acima da linha divisória referem-se aos subsistemas de inversores (FIX e TK); os grupos abaixo referem-se à estação solarimétrica (SS).

Grupo	Variável(is)	Descrição
<i>Subsistemas de inversores (Fixo e Rastreamento)</i>		
Potência AC	total_active_power_w, total_reactive_power_var	Potência ativa (W) e reativa (var) AC total injetada na rede
Grandezas AC	phase_(a,b,c)_voltage_v, phase_(a,b,c)_current_a, grid_frequency_hz, power_factor	Tensão (V) e corrente (A) trifásica, frequência da rede (Hz) e fator de potência
Potência DC	total_dc_power_w	Potência DC total gerada pelo array (W)
MPPT	mppt_voltage_v[0], mppt_current_a[0]	Tensão (V) e corrente (A) DC no canal MPPT ativo
Energia gerada	daily/monthly/ total_power_yields_kwh	Energia acumulada diária, mensal e total (kWh)
Operação	work_state(1-3), fault_code	Estados operacionais e códigos de falha do inversor
Temperatura	internal_temperature_ _celsius	Temperatura interna do inversor (°C)
<i>Estação solarimétrica (SS)</i>		
Irradiância	poa/ghi/gri_irradiancia	Irradiância no plano do array (POA), horizontal global (GHI) e refletida (GRI) (W/m ²)
Estat. irradiância	*_irr_(med,max,min), *_kwh_(hour,day,acc)	Agregados estatísticos e integrais de energia das componentes de irradiância
Temperatura	temperatura_painel, air_temperature, pv_temperatura	Temperaturas de módulo e ambiente com agregados estatísticos (°C)
Vento	vel_vento, air_speed_(med,max,min), dir_vento	Velocidade (m/s) e direção do vento (°) com agregados
Precipitação	precipitacao_acc	Precipitação acumulada (mm)
Auxiliar	tensao_bateria	Tensão da bateria do <i>datalogger</i> (V)

Fonte: Adaptado de Rodrigues et al. (19).




– Pipeline de pré-processamento e avaliação. Os dados brutos dos inversores (A1) e da estação solarimétrica (A2) são integrados e submetidos a quatro etapas sequenciais de pré-processamento (preenchimento noturno, interpolação linear, imputação KNN e segmentação em trechos contínuos), seguidas por seleção de atributos, normalização, janelamento temporal, particionamento treino/validação/teste, treinamento dos modelos e avaliação por meio de RMSE, MAE e R^2 .

Fonte: Adaptado de Rodrigues et al. (19).

Tabela 4 – Redução de dados ausentes (%) ao longo das etapas do pipeline de pré-processamento para os subsistemas fixo e com rastreamento.

<i>Dataset</i>	Grupo de variáveis	Etapa 1 (%)	Etapa 2 (%)	Etapa 3 (%)	Etapa 4 (%)
Fixo	Vento, temp., precip. e operacionais	7,69	7,69	4,53	1,67
	Irradiância e derivadas	7,69	3,36	1,67	1,67
	Variável alvo (<code>total_active_power_w</code>)	12,87	5,03	1,55	1,25
Rastreamento	Vento, temp., precip. e operacionais	7,69	7,69	4,53	1,67
	Irradiância e derivadas	7,69	3,36	1,67	1,67
	Variável alvo (<code>total_active_power_w</code>)	16,80	7,85	1,45	1,25

Fonte: Adaptado de Rodrigues et al. (19).



– Estratégia metodológica progressiva desta dissertação. Os três experimentos compartilham a mesma base de dados e pipeline de pré-processamento, aprofundando sucessivamente a análise: de modelos de referência (Exp. 1), à engenharia de atributos e otimização (Exp. 2), à avaliação de modelos baseados em LLM em múltiplas resoluções (Exp. 3).

Fonte: Elaborado pelo autor.

4 RESULTADOS E DISCUSSÃO

Este capítulo apresenta e discute os resultados obtidos nos três experimentos descritos no Capítulo 3, articulando-os como uma investigação progressiva sobre a previsão de geração fotovoltaica em sistemas de configuração *Twin-Plant*. A Seção 4.1 trata dos resultados de referência com janela deslizante e hiperparâmetros padrão, estabelecendo o patamar base de desempenho e caracterizando a influência da sazonalidade e da topologia de montagem. A Seção 4.2 analisa os ganhos obtidos pela engenharia de atributos temporais e pela otimização bayesiana de hiperparâmetros, isolando a contribuição de cada componente metodológico. A Seção 4.3 posiciona os modelos baseados em *Large Language Models* frente aos algoritmos clássicos, identificando as condições em que cada paradigma oferece vantagem relativa. Por fim, a Seção 4.4 integra os resultados dos três experimentos em uma discussão unificada, respondendo às questões de pesquisa formuladas nesta dissertação.

4.1 EXPERIMENTO 1: MODELOS DE REFERÊNCIA COM JANELA DESLIZANTE

4.1.1 Desempenho Geral dos Modelos

A Tabela 5 apresenta o desempenho dos modelos avaliados no Experimento 1 para os dois subsistemas da configuração *Twin-Plant* ao longo das quatro estações do ano. Os resultados revelam que os métodos de *ensemble* baseados em árvores de decisão — Random Forest (RF), XGBoost (XGB) e LightGBM (LGBM) — alcançaram desempenho consistentemente superior ou equivalente ao da LSTM em termos de RMSE e R^2 na maioria dos cenários sazonais.

Tabela 5 – Desempenho sazonal dos modelos de previsão (MAE e RMSE em W; R^2 adimensional) para os subsistemas fixo e com rastreamento. Melhores resultados por estação e subsistema em negrito.

Sistema	Estação	RF			XGB			LGBM			LSTM		
		MAE	RMSE	R^2	MAE	RMSE	R^2	MAE	RMSE	R^2	MAE	RMSE	R^2
Fixo	Verão	7.273	15.130	0,885	7.670	15.750	0,876	7.450	15.660	0,877	9.490	17.590	0,843
	Outono	5.935	15.290	0,869	6.290	15.730	0,863	6.180	15.720	0,863	7.180	15.540	0,866
	Inverno	4.096	10.590	0,935	4.550	11.680	0,921	4.500	11.110	0,929	4.580	9.950	0,942
	Primavera	5.355	13.030	0,902	5.910	13.910	0,888	6.080	14.240	0,883	7.200	14.190	0,883
Rastreamento	Verão	8.276	16.940	0,871	8.800	17.660	0,860	8.630	17.540	0,862	8.470	16.100	0,886
	Outono	5.548	14.540	0,856	5.730	14.850	0,850	5.900	15.140	0,844	7.080	15.360	0,839
	Inverno	3.741	10.100	0,937	4.440	11.520	0,921	4.230	10.950	0,927	4.350	9.920	0,937
	Primavera	6.030	13.830	0,903	6.520	14.650	0,891	6.560	14.530	0,893	6.610	14.520	0,893

Fonte: Elaborado pelo autor.

De modo geral, o RF apresentou os resultados mais estáveis e acurados entre os modelos de *ensemble*, obtendo o menor MAE em seis das oito combinações estação/subsistema. A LSTM demonstrou desempenho competitivo em cenários específicos — em particular no

inverno, onde alcançou o maior R^2 para o sistema fixo (0,942) — mas com degradação expressiva no verão, especialmente no sistema de rastreamento, indicando sensibilidade à variabilidade dos dados.

4.1.2 Influência da Sazonalidade

A sazonalidade é o principal fator determinante da acurácia da previsão fotovoltaica, superando em importância a escolha do algoritmo. No inverno, os erros MAE variam aproximadamente entre 3.741 e 4.580 W, enquanto no verão essa faixa se eleva para 7.273–9.490 W, representando uma degradação de 40% a 50% na acurácia da previsão em relação à melhor estação.

Esse comportamento está diretamente associado à variabilidade da irradiância solar. No inverno, predominam condições atmosféricas mais estáveis, com menor incidência de nuvens convectivas e transições abruptas, resultando em séries temporais mais suaves e previsíveis. Em condições de menor irradiância, o sistema opera em um regime mais próximo da linearidade, facilitando a modelagem. O verão, em contraste, é caracterizado por alta variabilidade e ocorrência frequente de sombreamento intermitente por nuvens convectivas, que introduzem flutuações de alta frequência na potência gerada. Em condições de alta irradiância, efeitos não lineares — como a influência térmica e variações rápidas de potência — tornam a relação entre variáveis meteorológicas e geração mais complexa.

A primavera apresenta comportamento intermediário, com R^2 em torno de 0,88–0,90, enquanto o outono se posiciona próximo ao inverno em acurácia, com R^2 entre 0,84 e 0,87, porém com diferenças relevantes entre os dois subsistemas, conforme discutido na próxima subseção.

4.1.3 Influência da Topologia de Montagem

A comparação entre os subsistemas fixo e com rastreamento revela padrões distintos por estação, evidenciando que a dificuldade de previsão do sistema com rastreamento não é uniforme ao longo do ano.

No verão e na primavera, o sistema com rastreamento apresenta erros consistentemente superiores aos do sistema fixo, com diferenças da ordem de 5% a 15% no MAE. Isso está associado à dinâmica adicional introduzida pelo movimento dos módulos: o rastreamento maximiza a irradiância incidente (POA), produzindo um perfil com *plateau* mais pronunciado e rampas de abertura e fechamento mais abruptas. A maior sensibilidade da irradiância POA a variações rápidas de nebulosidade amplifica flutuações de curto prazo na potência gerada, tornando a série temporal mais irregular. Adicionalmente, a estratégia de *backtracking* introduz não linearidades e dependências geométricas que não são explicitamente capturadas pelos algoritmos preditivos.

No inverno, a diferença de desempenho entre os sistemas torna-se pouco significativa, com valores de R^2 praticamente idênticos (0,935–0,942), indicando que, em condições atmosféricas estáveis, a dinâmica do rastreamento tem impacto reduzido sobre a previsibilidade.


O outono apresenta o comportamento mais peculiar: o sistema com rastreamento registra erros menores do que o sistema fixo, com diferenças no MAE da ordem de 3% a 8%. Esse resultado sugere que, em regimes intermediários de irradiância com menor variabilidade atmosférica do que o verão, a dinâmica do rastreamento pode favorecer a previsibilidade — possivelmente pela combinação entre menor turbulência na cobertura de nuvens e o aproveitamento angular mais eficiente da radiação solar pelo rastreador, que resulta em uma série temporal com estrutura temporal mais regular do que o sistema fixo nessa estação específica.

4.2 EXPERIMENTO 2: ENGENHARIA DE ATRIBUTOS TEMPORAIS E OTIMIZAÇÃO BAYESIANA

4.2.1 Impacto das Estratégias de Modelagem

O Experimento 2 investigou quatro estratégias progressivas de modelagem, permitindo isolar a contribuição de cada componente metodológico. Os resultados consolidados são apresentados nos mapas de calor das Figuras 6 e 7, que exibem os valores de R^2 e EAM (em W) para todas as combinações estação $\times$ estratégia $\times$ modelo para ambos os subsistemas.


– Mapa de calor do R^2 para as quatro estratégias de modelagem e três algoritmos de *ensemble*, por estação do ano e subsistema. Valores mais altos (tons mais escuros) indicam melhor desempenho.



Fonte: Adaptado de Rodrigues et al. (60).

A análise dos mapas de calor revela que, independentemente do modelo utilizado, os padrões de desempenho são fortemente condicionados pela estação do ano e pelo tipo

– Mapa de calor do Erro Absoluto Médio (EAM, em W) para as quatro estratégias de modelagem e três algoritmos de *ensemble*, por estação do ano e subsistema. Valores mais baixos (tons mais claros) indicam melhor desempenho.



Fonte: Adaptado de Rodrigues et al. (60).

de sistema (fixo ou com rastreamento). Esse comportamento reforça que a variabilidade do processo físico — e não a escolha do algoritmo — é o principal fator determinante da acurácia da previsão, em consonância com os resultados do Experimento 1.

4.2.2 Contribuição de Cada Componente Metodológico

A análise isolada de cada componente revela uma hierarquia clara de impacto sobre o desempenho preditivo.

Estratégia base (janela deslizante): constitui o patamar de referência, com desempenho equivalente ao do Experimento 1. Os erros MAE situam-se entre 6.700 e 8.800 W no verão e entre 3.400 e 4.500 W no inverno para o sistema fixo.

Grid Search: a busca exaustiva de hiperparâmetros produz melhorias marginais sobre a estratégia base, com reduções de MAE inferiores a 3% na maioria dos cenários. Isso indica que os hiperparâmetros padrão das bibliotecas são razoavelmente bem calibrados para este tipo de problema.

Otimização Bayesiana (Optuna/TPE): a otimização bayesiana supera consistentemente o Grid Search, com menor número de avaliações e ganhos ligeiramente superiores em todas as estações. As reduções adicionais de MAE em relação ao Grid Search são, contudo, da mesma ordem que as obtidas por este último em relação à estratégia base — geralmente inferiores a 3–5%.

Atributos de defasagem (Lag Features) + Otimização Bayesiana: a incorporação de atributos de defasagem temporal representa o componente de maior impacto isolado na cadeia metodológica, mas seu efeito é assimétrico entre estações e subsistemas. Para o sistema fixo no verão, o MAE cai de aproximadamente 7.273 W (base)

para 6.720 W com *lag features* + otimização bayesiana — uma redução de cerca de 7,6%. Para o sistema com rastreamento na mesma estação, a redução é da ordem de 9,2%, de 8.276 W (base RF) para 7.517 W (Lag + Bayesiana RF). Os ganhos mais expressivos ocorrem nas estações de maior variabilidade (verão e outono do sistema com rastreamento, entre 7% e 9,2%) e no inverno do sistema fixo (15,7%); já no inverno do sistema com rastreamento e na primavera de ambos os subsistemas, os ganhos são modestos (1,6% a 2,2%) ou, no caso da primavera do sistema fixo, ligeiramente negativos (−0,6%), indicando que a estratégia base já captura adequadamente a dinâmica nessas condições de menor variabilidade.

A Tabela 6 sintetiza os valores de MAE e R^2 da melhor estratégia (Lag Features + Otimização Bayesiana) com o Random Forest para ambos os subsistemas ao longo das quatro estações, e os compara com a estratégia base.

Tabela 6 – Comparação entre a estratégia base e a melhor estratégia (Lag Features + Otimização Bayesiana com RF) em termos de MAE (W) e R^2 , por subsistema e estação.

Sistema	Estação	Base (RF)		Lag Feats + Bayesiana (RF)	
		MAE (W)	R^2	MAE (W)	R^2
Fixo	Verão	7.273	0,885	6.720	0,892
	Outono	5.935	0,869	5.648	0,887
	Inverno	4.096	0,935	3.453	0,948
	Primavera	5.355	0,902	5.388	0,901
Rastreamento	Verão	8.276	0,871	7.517	0,872
	Outono	5.548	0,856	5.161	0,884
	Inverno	3.741	0,937	3.657	0,945
	Primavera	6.030	0,903	5.932	0,905

Fonte: Elaborado pelo autor.

4.2.3 Análise das Defasagens por Variável

A análise das funções de autocorrelação (ACF) e correlação cruzada (CCF), descritas na Seção 3.5.2, revelou padrões fisicamente interpretáveis que orientaram a seleção das defasagens.

A ACF da série de potência fotovoltaica confirma autocorrelação significativa por aproximadamente 30–40 passos (2,5–3,3 horas), com picos periódicos bem definidos nos passos 144 e 288 (12 e 24 horas), associados ao ciclo solar diário. As defasagens finas (1 a 12 passos) capturam a dinâmica imediata do sistema e são as mais relevantes para a previsão de curto prazo (horizonte de 5 minutos), pois a autocorrelação nessa faixa é superior a 0,90 para ambos os subsistemas. As defasagens periódicas (144 e 288 passos)

introduzem informação sobre o padrão solar do dia anterior, que é particularmente útil em dias com padrão meteorológico similar ao precedente.

A CCF entre a irradiância e a potência ativa confirma o efeito praticamente instantâneo da irradiância sobre a geração (pico em defasagem zero), com correlação superior a 0,93 para POA e GHI em ambos os subsistemas. A temperatura do painel exibiu pico de CCF deslocado para defasagens negativas ($\text{lag} = -1$ a -2), evidenciando o atraso térmico esperado: a inércia do painel faz com que sua temperatura responda à irradiância com retardo de 5 a 10 minutos, de modo que a temperatura no instante t reflete a irradiância em $t - 1$ ou $t - 2$.

A inclusão do termo de interação irradiância $\times$ temperatura do painel captura o efeito físico de redução de eficiência com o aumento de temperatura, que não é linearmente separável das contribuições individuais das duas variáveis. Esse atributo demonstrou contribuição positiva para o desempenho, especialmente no verão e na primavera, quando as temperaturas de módulo são mais elevadas e a degradação de eficiência mais pronunciada.

4.2.4 Padrão Sazonal e por Topologia no Experimento 2

Os mapas de calor confirmam e reforçam os padrões identificados no Experimento 1. A melhoria obtida pelos atributos de defasagem é proporcionalmente maior nas estações de maior variabilidade (verão e primavera), onde o contexto histórico recente carrega informação relevante sobre a evolução da cobertura de nuvens. No inverno, a melhoria é menor em termos proporcionais, mas ainda significativa em termos absolutos, dado o já elevado R^2 de base.

A comparação entre os subsistemas mantém o padrão observado no Experimento 1: no verão e na primavera, o sistema com rastreamento apresenta erros superiores ao sistema fixo em todos os cenários de estratégia. No outono, o sistema com rastreamento mantém a vantagem de previsibilidade observada no Experimento 1, com MAE tipicamente 3% a 8% inferior ao sistema fixo após a aplicação de *lag features*. No inverno, as diferenças são novamente mínimas entre os dois subsistemas.


A Figura 8 apresenta a comparação direta entre os subsistemas fixo e com rastreamento utilizando a estratégia de otimização bayesiana, evidenciando as diferenças de desempenho por estação e os padrões de dispersão dos resultados.

4.3 EXPERIMENTO 3: MODELOS BASEADOS EM LLM VERSUS ALGORITMOS CLÁSSICOS

4.3.1 Resultados Quantitativos — Resolução de 5 Minutos

A Tabela 7 consolida os resultados de MAE, RMSE e R^2 para a resolução de 5 minutos, para ambos os subsistemas. O resultado central é a superioridade sistemática

– Comparação de EAM, REQM e R^2 entre o sistema fixo e o sistema com rastreamento por estação do ano, utilizando a estratégia de otimização bayesiana. Barras agrupadas por algoritmo (RF, XGB, LGBM).



Fonte: Adaptado de Rodrigues et al. (60).

dos modelos clássicos de *ensemble* sobre as abordagens baseadas em LLM, com uma única exceção pontual: no sistema fixo em 5 minutos, o XGBoost (RMSE = 16.627,8 W) apresenta RMSE marginalmente superior ao do Prophet (RMSE = 16.542,6 W), o melhor LLM nesse cenário — uma diferença de apenas 0,5%, sem relevância prática, e que se inverte em MAE e em R^2 , onde o XGBoost continua superior ao Prophet. Em todos os demais cenários e métricas, os modelos clássicos superam integralmente os LLMs avaliados.

Tabela 7 – Desempenho preditivo por modelo e subsistema na resolução de 5 minutos (partição 70/15/15). Melhores resultados por subsistema em negrito.

Grupo	Modelo	Subsistema	MAE (W)	RMSE (W)	R^2
Clássico	LGBM	Fixo	7.458	16.025,9	0,8531
Clássico	RF	Fixo	7.470	16.027,4	0,8531
Clássico	XGB	Fixo	7.716	16.627,8	0,8419
LLM	Prophet	Fixo	8.761	16.542,6	0,8435
LLM	Time-LLM	Fixo	11.633	21.435,2	0,7351
LLM	Chronos	Fixo	11.819	25.021,5	0,6420
Clássico	LGBM	Rastreamento	7.574	16.300,2	0,8687
Clássico	RF	Rastreamento	7.681	16.360,9	0,8678
Clássico	XGB	Rastreamento	8.098	17.113,7	0,8553
LLM	Prophet	Rastreamento	10.888	19.475,8	0,8127
LLM	Time-LLM	Rastreamento	12.884	23.005,6	0,7372
LLM	Chronos	Rastreamento	13.933	28.617,9	0,5955

Fonte: Adaptado de Rodrigues et al. (56).

Na resolução de 5 minutos, o LGBM registra RMSE de 16.025,9 W e MAE de

7.458 W ($R^2 = 0,8531$) no sistema fixo, ante RMSE de 16.542,6 W e MAE de 8.761 W do Prophet — o melhor LLM no mesmo cenário. A fronteira entre os dois grupos é particularmente nítida nas métricas RMSE e R^2 : mesmo o pior modelo clássico (XGB, com RMSE de 16.627,8 W no sistema fixo) supera o melhor LLM (Prophet, 16.542,6 W) em MAE e em R^2 , sendo praticamente equivalente em RMSE nesse cenário específico. Para o Chronos, a lacuna é expressiva: RMSE de 25.021,5 W no sistema fixo e 28.617,9 W no sistema de rastreamento, representando degradação de 56% e 75%, respectivamente, em relação ao LGBM.

É importante notar uma assimetria metodológica entre o Experimento 2 e o Experimento 3: os modelos clássicos avaliados neste experimento (RF, XGB e LGBM) operam com hiperparâmetros padrão das respectivas bibliotecas e sem a engenharia de atributos de defasagem (*lag features*) introduzida no Experimento 2, conforme descrito na Seção 3.6.2. Essa escolha foi deliberada, de modo a estabelecer uma comparação em condições equiparáveis de esforço de configuração entre os dois paradigmas — uma vez que os modelos baseados em LLM aqui avaliados também não foram submetidos a um processo de busca de hiperparâmetros tão extenso quanto o do Experimento 2. Ainda assim, essa escolha implica que a vantagem dos modelos clássicos reportada neste experimento é, em certo sentido, conservadora: os mesmos algoritmos, quando combinados com as estratégias de otimização bayesiana e engenharia de atributos do Experimento 2, atingem R^2 superior a 0,94 no inverno (Tabela 6), uma margem ainda mais ampla frente aos LLMs do que a observada com hiperparâmetros padrão. A vantagem dos modelos clássicos sobre os LLMs avaliados nesta seção deve, portanto, ser interpretada como um limite inferior, e não como o máximo benefício possível da abordagem clássica.

4.3.2 Resultados Quantitativos — Resolução de 1 Hora

A Tabela 8 apresenta os resultados para a resolução de 1 hora. A reamostagem por média aritmética atenua o ruído de alta frequência e reduz a variabilidade instantânea, o que tende a beneficiar modelos menos flexíveis; contudo, a hierarquia entre os grupos se mantém inalterada.

Na resolução horária, o LGBM supera o Prophet em 17% no RMSE (15.201,9 vs. 17.835,9 W) e em 21% no MAE (8.263 vs. 10.471 W) no sistema fixo. O Chronos é superado em 69% no RMSE pelo LGBM no mesmo cenário. Para o sistema com rastreamento em 1 hora, o RF registra o melhor resultado entre todos os modelos ($R^2 = 0,8333$), com o LGBM em segundo lugar ($R^2 = 0,8311$) — a inversão de liderança entre RF e LGBM nesse cenário é marginal e não estatisticamente significativa.

A reamostagem para 1 hora beneficia o Time-LLM em relação à resolução de 5 minutos — seu RMSE no sistema fixo cai de 21.435,2 W para 18.642,7 W —, possivelmente porque a resolução horária é mais compatível com o comprimento de contexto configurado

Tabela 8 – Desempenho preditivo por modelo e subsistema na resolução de 1 hora (partição 70/15/15). Melhores resultados por subsistema em negrito.

Grupo	Modelo	Subsistema	MAE (W)	RMSE (W)	R^2
Clássico	LGBM	Fixo	8.263	15.201,9	0,8480
Clássico	RF	Fixo	8.473	15.479,3	0,8424
Clássico	XGB	Fixo	8.733	15.639,9	0,8392
LLM	Prophet	Fixo	10.471	17.835,9	0,7914
LLM	Time-LLM	Fixo	9.824	18.642,7	0,7679
LLM	Chronos	Fixo	13.004	25.723,2	0,5660
Clássico	RF	Rastreamento	9.051	17.194,6	0,8333
Clássico	LGBM	Rastreamento	9.263	17.310,6	0,8311
Clássico	XGB	Rastreamento	9.338	17.386,4	0,8296
LLM	Prophet	Rastreamento	13.277	20.402,0	0,7658
LLM	Time-LLM	Rastreamento	12.033	21.839,7	0,7269
LLM	Chronos	Rastreamento	13.697	26.275,6	0,6115

Fonte: Adaptado de Rodrigues et al. (56).

(`seq_len` = 96 pontos $\approx$ 4 dias em 1 hora vs. 8 horas em 5 minutos). Esse resultado apoia a hipótese de que a configuração inadequada do contexto é uma das limitações centrais do Time-LLM em séries fotovoltaicas de alta resolução.


4.3.3 Impacto Diferencial da Estrutura de Montagem sobre os Modelos

Em todos os modelos avaliados, o sistema com rastreamento resultou em valores de RMSE superiores aos do sistema fixo na resolução de 5 minutos, confirmando o padrão identificado nos experimentos anteriores. A Figura 9 ilustra esse impacto para todos os modelos na resolução de 5 minutos.

Os modelos clássicos demonstram maior robustez à variação de topologia: o LGBM registra $\Delta R^2 = +0,0156$ (de 0,8531 para 0,8687) na transição do sistema fixo para o de rastreamento em 5 minutos — resultado aparentemente contra-intuitivo que pode ser explicado pelo fato de o *plateau* de irradiância gerado pelo rastreamento facilitar a regressão local nos momentos de máxima geração.

Os LLMs sofrem penalidade proporcionalmente maior na mesma transição. O Chronos perde $\Delta R^2 = -0,0465$ (de 0,6420 para 0,5955) e o Prophet $\Delta R^2 = -0,0308$ (de 0,8435 para 0,8127) em 5 minutos. Na resolução horária, o Prophet apresenta queda de $-0,0256$ (de 0,7914 para 0,7658). A incapacidade do Chronos de incorporar covariáveis exógenas é particularmente penalizante para o sistema com rastreamento, cujas flutuações não sazonais são capturáveis apenas por meio de informação meteorológica contextual —

- Impacto da estrutura física (fixa vs. rastreamento) em RMSE e R^2 para todos os modelos avaliados, resolução de 5 minutos. Os LLMs sofrem penalidade proporcionalmente maior na transição para o sistema com rastreamento.



Fonte: Adaptado de Rodrigues et al. (56).

informação que o modelo é estruturalmente incapaz de processar.

4.3.4 Análise Qualitativa das Previsões

A Figura 10 apresenta os primeiros 168 pontos do conjunto de teste para ambos os subsistemas na resolução de 1 hora, permitindo uma análise visual dos padrões de erro de cada modelo.

Os modelos clássicos acompanham as flutuações intradiárias e os ciclos diários com fidelidade em ambas as configurações. O Prophet produz previsões suaves e fisicamente plausíveis no sistema fixo, mas subestima sistematicamente os picos de geração no sistema com rastreamento, onde as rampas de *ramp-up* e *ramp-down* são mais abruptas do que o componente sazonal rígido da decomposição aditiva consegue capturar. O Chronos captura corretamente a amplitude do *plateau* de geração, mas falha consistentemente nas transições de rampa e acumula desvio crescente ao longo da janela de previsão. O Time-LLM apresenta, em alguns instantes noturnos, previsões não nulas — evidência da ausência de garantias físicas nas previsões, exigindo pós-processamento corretivo em aplicações operacionais.

4.3.5 Diagnóstico das Limitações Arquiteturais dos LLMs

Os resultados permitem identificar as origens estruturais do desempenho inferior de cada abordagem baseada em LLM, revelando que as dificuldades não decorrem de um fator isolado, mas de restrições arquiteturais distintas.

O **Chronos** demonstra que *foundation models* são capazes de produzir previsões fisicamente razoáveis sem treinamento específico no domínio-alvo — vantagem real em

cenários com dados históricos escassos. Contudo, a ausência de suporte a covariáveis exógenas impõe um teto de acurácia intransponível quando instrumentação meteorológica está disponível: o modelo é forçado a inferir variações de geração exclusivamente a partir do histórico da série-alvo, ignorando sinais físicos diretamente causais como irradiância e temperatura do módulo.

O **Time-LLM**, embora multivariado, tem seu desempenho fortemente condicionado ao valor de `seq_len`: janelas de contexto inadequadas impedem a captura dos padrões de periodicidade diária da série fotovoltaica. Na resolução de 5 minutos, a janela de 96 passos corresponde a apenas 8 horas de histórico, insuficiente para capturar um ciclo solar completo. Adicionalmente, as falhas de paridade evidenciam a ausência de garantias físicas nas predições.

O **Prophet** é estruturalmente penalizado pela imposição de componentes sazonais rígidos sobre séries com não-estacionariedades locais pronunciadas. A decomposição aditiva pressupõe padrões sazonais estáveis e repetíveis — premissa que não se sustenta diante de variabilidade meteorológica abrupta e das dinâmicas de *ramp-up* e *ramp-down* características do sistema com rastreamento.

Uma hipótese central da literatura de LLMs para séries temporais é que a capacidade de modelar dependências de longo alcance via mecanismos de atenção confeririam vantagem sobre algoritmos clássicos. Os resultados do Experimento 3 questionam essa hipótese no contexto fotovoltaico: na presença de covariáveis meteorológicas de alta qualidade, a relação irradiância-potência é fisicamente determinista em condições de céu limpo e suficientemente capturável por regressores não lineares locais, sem que se demande o custo computacional e de infraestrutura das arquiteturas de LLM.

4.3.6 Considerações sobre Custo Computacional

Embora esta dissertação não tenha realizado uma medição sistemática de tempo de treinamento e de inferência — o que é apontado como uma lacuna a ser preenchida em trabalhos futuros —, a natureza arquitetural dos modelos avaliados permite uma discussão qualitativa relevante para a aplicação prática dos resultados. Os modelos de *ensemble* (RF, XGB e LGBM) operam sobre um vetor de atributos tabular de baixa dimensionalidade, com treinamento e inferência tipicamente da ordem de segundos a poucos minutos em hardware convencional (CPU), sem dependência de aceleração por GPU. Em contraste, o Time-LLM reprograma um *backbone* GPT-2 — ainda que com ajuste fino restrito a camadas específicas —, exigindo recursos de GPU tanto para o treinamento quanto, em menor grau, para a inferência; o Chronos, operando em modo *zero-shot*, dispensa treinamento específico ao domínio, mas seu *rolling forecast* realimentado por valores reais implica múltiplas chamadas sequenciais de inferência sobre uma arquitetura T5, mais custosas por amostra do que a predição de um modelo de *ensemble*; o Prophet,

por sua vez, tem custo computacional comparável ao dos modelos clássicos, já que sua decomposição aditiva não depende de redes neurais profundas. Essa assimetria de custo computacional reforça, em uma dimensão adicional à puramente preditiva, a conclusão de que os modelos de *ensemble* oferecem a relação mais favorável entre desempenho e custo de infraestrutura para a previsão fotovoltaica de curto prazo nas condições avaliadas — uma vez que, como demonstrado nas seções anteriores, eles não apenas igualam, mas superam substancialmente a acurácia dos modelos baseados em LLM, fazendo-o com exigência computacional comparativamente menor.

4.4 SÍNTESE INTEGRADA DOS TRÊS EXPERIMENTOS

4.4.1 Evolução do Desempenho ao Longo da Pesquisa

A Tabela 9 integra os principais resultados dos três experimentos para o melhor modelo de cada etapa, permitindo visualizar a evolução do desempenho preditivo ao longo da pesquisa para ambos os subsistemas.

Tabela 9 – Evolução do desempenho preditivo ao longo dos três experimentos (MAE em W; R^2 adimensional). Resultados do melhor modelo de cada etapa, média das quatro estações.

Experimento	Configuração	Modelo	MAE médio (W)	R^2 médio
Exp. 1 — Base	Janela deslizante, hiperp. padrão	RF	5.665	0,898
Exp. 1 — Base	Janela deslizante, hiperp. padrão	RF	5.899	0,892
Exp. 2 — Lag + Bayes	Lag features + Optuna	RF	5.302	0,907
Exp. 2 — Lag + Bayes	Lag features + Optuna	RF	5.567	0,902
Exp. 3 — LLM (5 min)	Direto, hiperp. padrão	LGBM	7.458	0,8531
Exp. 3 — LLM (5 min)	Direto, hiperp. padrão	LGBM	7.574	0,8687

Linha 1 de cada bloco: sistema fixo. Linha 2: sistema com rastreamento.

Fonte: Elaborado pelo autor.

A progressão de Exp. 1 para Exp. 2 demonstra que a engenharia de atributos temporais guiada por análise estatística (ACF/CCF) é o componente metodológico de maior impacto isolado, com redução média de MAE de aproximadamente 6,4% para o sistema fixo e 5,6% para o sistema com rastreamento, considerando a média das quatro estações. Esses ganhos médios mascaram, contudo, uma variação expressiva entre estações: os ganhos de R^2 variam de $-0,07$ pp (primavera do sistema fixo, uma leve piora) a $+2,83$ pp (outono do sistema com rastreamento), com destaque para o outono — a estação em que a engenharia de atributos mais contribui em ambos os subsistemas — enquanto estações de irradiância já bem comportada pela estratégia base, como o verão do sistema com rastreamento ($+0,06$ pp) e a primavera do sistema fixo, apresentam ganhos marginais ou nulos. Esse padrão indica que a incorporação de conhecimento do domínio físico no

processo de construção de atributos é mais impactante do que a sofisticação do algoritmo por si só, mas seu benefício relativo depende da estação e do subsistema considerados.

4.4.2 Respostas às Questões de Pesquisa

Os resultados dos três experimentos permitem responder às questões de pesquisa formuladas nesta dissertação.

Q1: Em que medida a sazonalidade condiciona a acurácia da previsão fotovoltaica de curto prazo?

A sazonalidade é o principal fator determinante da acurácia preditiva, com diferenças de MAE de 40% a 50% entre o inverno (melhor desempenho) e o verão (pior desempenho), independentemente do algoritmo utilizado. Esse padrão é consistente em todos os três experimentos e em ambos os subsistemas. A variabilidade da irradiância solar — governada pela incidência de nuvens convectivas e pela estabilidade atmosférica — é o mecanismo causal subjacente.

Q2: Como a topologia de montagem (fixa vs. rastreamento) afeta a previsibilidade da geração fotovoltaica?

O impacto da topologia de montagem é sazonal e não uniforme. No verão e na primavera, o sistema com rastreamento é 5% a 15% mais difícil de prever (MAE superior), em razão das dinâmicas de *ramp-up/ramp-down* e da maior sensibilidade da irradiância POA à variabilidade de curto prazo. No inverno, as diferenças entre sistemas são mínimas. No outono, o sistema com rastreamento apresenta maior previsibilidade do que o fixo, sugerindo uma interação entre a dinâmica do rastreador e o regime de irradiância intermediário característico dessa estação no Cerrado brasileiro. Essa assimetria estacional é o resultado mais relevante e menos óbvio dos experimentos.

Q3: Qual é o impacto da engenharia de atributos temporais sobre o desempenho preditivo dos modelos de *ensemble*?

A engenharia de atributos temporais baseada em defasagens, guiada por ACF e CCF, é o componente metodológico de maior impacto individual na cadeia de modelagem, mas seu efeito é assimétrico entre estações e subsistemas: reduções de MAE de até 15,7% no inverno do sistema fixo e entre 7% e 9,2% no verão e no outono do sistema com rastreamento, frente a ganhos modestos (1,6% a 2,2%) ou nulos (primavera do sistema fixo, -0,6%) nas estações de irradiância mais estável. Os ganhos absolutos de MAE são proporcionalmente maiores nas estações de maior variabilidade, onde o contexto histórico recente carrega mais informação sobre a evolução do estado atmosférico; nas estações mais estáveis, a estratégia base de janela deslizante já captura boa parte da dinâmica relevante, restando menos espaço de melhoria para a engenharia de atributos.

Q4: Os modelos baseados em LLM superam os algoritmos clássicos de

***ensemble* na previsão fotovoltaica com covariáveis meteorológicas disponíveis?**


Não, com uma única ressalva pontual sem relevância prática. Os resultados do Experimento 3 demonstram que os modelos clássicos de *ensemble* superam os modelos baseados em LLM avaliados em praticamente todas as combinações de subsistema, resolução temporal e métrica — a única exceção, em um total de 12 combinações de métrica $\times$ subsistema $\times$ resolução, é o RMSE do sistema fixo em 5 minutos, em que o XGBoost (16.627,8 W) fica 0,5% acima do Prophet (16.542,6 W), sem que essa diferença se reproduza em MAE ou em R^2 no mesmo cenário. Nas demais 11 combinações avaliadas, a superioridade do melhor modelo clássico sobre o melhor LLM é integral, com diferença de até 17% no RMSE e 21% no MAE para a resolução horária (LGBM vs. Prophet). As limitações identificadas nos LLMs são de natureza arquitetural: ausência de suporte a covariáveis exógenas (Chronos), sensibilidade ao comprimento de contexto e ausência de garantias físicas (Time-LLM) e rigidez sazonal (Prophet).

4.4.3 Implicações Práticas para Sistemas de Monitoramento e Despacho

Os resultados desta dissertação têm implicações diretas para o projeto de sistemas de previsão em usinas fotovoltaicas de escala utilitária:

- (i) **Seleção de modelo:** para previsão de curto prazo (5 minutos a 1 hora) com covariáveis meteorológicas disponíveis, modelos de *ensemble* — especialmente LGBM e RF — oferecem a melhor relação desempenho/custo computacional. Não há justificativa empírica, nos cenários avaliados, para adotar arquiteturas de LLM.
- (ii) **Engenharia de atributos:** a incorporação de defasagens temporais selecionadas por ACF/CCF oferece ganhos expressivos de desempenho sem aumento de custo computacional. Essa etapa deve ser priorizada em pipelines operacionais.
- (iii) **Sazonalidade e incerteza:** sistemas de previsão fotovoltaica devem considerar explicitamente a variação sazonal do erro. Limites de confiança ou bandas de incerteza devem ser calibrados por estação para refletir adequadamente a variabilidade da irradiância ao longo do ano.
- (iv) **Topologia de montagem:** sistemas com rastreamento solar requerem estratégias preditivas específicas, especialmente no verão e na primavera. A ausência de variáveis que descrevam o ângulo real do rastreador ou o estado do *backtracking* é uma limitação que impede a modelagem explícita das dinâmicas de movimento dos módulos — e sua inclusão é apontada como direção prioritária para trabalhos futuros.

- Previsão vs. real para o sistema fixo (painel superior) e sistema com rastreamento (painel inferior), primeiros 168 pontos do conjunto de teste, resolução de 1 hora.



Fonte: Adaptado de Rodrigues et al. (56).

5 CONCLUSÃO

Esta dissertação investigou, a partir de uma planta fotovoltaica real em configuração *Twin-Plant* situada no cerrado brasileiro, como a sazonalidade meteorológica e a topologia de montagem condicionam a previsibilidade de curto prazo da geração de potência ativa, e em que medida algoritmos clássicos de aprendizado de máquina permanecem competitivos frente a arquiteturas emergentes baseadas em *Large Language Models*. A pesquisa foi conduzida em três etapas progressivas e cumulativas — apresentadas como Experimentos 1, 2 e 3 no Capítulo 4 —, que partiram da constituição de um *dataset* inédito, avançaram para uma análise comparativa sistemática entre subsistemas de montagem, e culminaram em um posicionamento crítico do estado da arte em modelagem preditiva. Este capítulo final sintetiza as conclusões gerais do trabalho, consolida suas contribuições, reconhece suas limitações e aponta direções para pesquisas futuras.

5.1 CONCLUSÕES GERAIS

O conjunto dos três experimentos permite concluir, em primeiro lugar, que a sazonalidade é o fator isolado de maior impacto sobre a acurácia da previsão fotovoltaica de curto prazo, superando em importância tanto a escolha do algoritmo quanto a topologia de montagem. Em todos os experimentos e em ambos os subsistemas, o inverno apresentou consistentemente o melhor desempenho preditivo, enquanto o verão apresentou o pior, com degradações de MAE da ordem de 40% a 50% entre as duas estações. Esse padrão está diretamente associado à estabilidade atmosférica: condições de céu mais limpo e menor incidência de nuvens convectivas no inverno produzem séries de irradiância e potência mais suaves e, portanto, mais previsíveis, enquanto o sombreamento intermitente característico do verão introduz não linearidades que desafiam os modelos avaliados.

Em segundo lugar, a topologia de montagem mostrou-se um fator relevante, porém não uniforme ao longo do ano — um resultado que só pôde ser estabelecido com confiança graças à configuração *Twin-Plant*, que elimina diferenças meteorológicas entre os subsistemas comparados. No verão e na primavera, o sistema com rastreamento solar é sistematicamente mais difícil de prever do que o sistema fixo, em razão das dinâmicas de *ramp-up* e *ramp-down* mais abruptas e da maior sensibilidade da irradiância no plano do módulo (POA) a variações rápidas de nebulosidade. No inverno, essa diferença praticamente desaparece. No outono, de forma notável, o padrão se inverte: o sistema com rastreamento torna-se mais previsível do que o fixo, sugerindo uma interação específica entre a dinâmica do rastreador e o regime de irradiância intermediário dessa estação no cerrado brasileiro. Esse achado — o de que a dificuldade preditiva do rastreamento solar é condicional, e não uma propriedade fixa da tecnologia — é uma das contribuições mais originais desta dissertação e dificilmente seria identificável sem o arranjo experimental

controlado da planta *Twin-Plant*.

Em terceiro lugar, no plano da modelagem, a incorporação de conhecimento físico do domínio na engenharia de atributos revelou-se mais determinante para o desempenho preditivo do que a sofisticação do algoritmo de aprendizado em si. A estratégia de defasagens temporais selecionadas a partir das funções de autocorrelação e correlação cruzada — e não a otimização de hiperparâmetros, seja por busca exaustiva ou bayesiana — foi o componente metodológico isolado de maior impacto, com reduções de MAE de até 15,7% em relação à abordagem de janela deslizante padrão, embora esse ganho seja assimétrico entre estações e subsistemas, sendo mais modesto nas condições de irradiância já bem comportada pela estratégia base. Esse resultado reforça a tese de que, em problemas de previsão fisicamente estruturados como a geração fotovoltaica, o esforço de modelagem é mais bem investido na representação do problema do que na busca por algoritmos cada vez mais complexos.

Por fim, e talvez a conclusão de maior relevância prática desta dissertação, os resultados do Experimento 3 demonstram que os modelos baseados em *Large Language Models* avaliados — Time-LLM, Chronos e Prophet — não superam os algoritmos clássicos de *ensemble* em praticamente nenhum dos cenários testados, seja na resolução de 5 minutos, seja na resolução horária, e independentemente do subsistema considerado — com a única ressalva pontual e sem relevância prática do RMSE do sistema fixo em 5 minutos, em que o XGBoost e o Prophet apresentam desempenho estatisticamente equivalente. Essa conclusão é especialmente significativa porque foi obtida sob condições favoráveis aos LLMs: dados reais, covariáveis meteorológicas de alta qualidade disponíveis e múltiplas resoluções temporais avaliadas. Quando a relação entre as variáveis preditoras e a variável-alvo é fisicamente determinista — como é o caso da relação irradiância-potência em condições de céu razoavelmente previsível —, regressores não lineares locais como os modelos de *ensemble* capturam essa relação de forma mais eficiente, sem demandar o custo computacional, de infraestrutura e de engenharia associado às arquiteturas baseadas em atenção e em grandes modelos de linguagem.

Em síntese, a hipótese subjacente a esta dissertação — de que a configuração *Twin-Plant* permite isolar e quantificar separadamente os efeitos da variabilidade meteorológica, da topologia de montagem e da escolha do paradigma de modelagem sobre a previsibilidade da geração fotovoltaica — foi confirmada pelos resultados obtidos nos três experimentos, fornecendo uma base empírica coerente e articulada para a tomada de decisão em aplicações reais de previsão solar.

5.2 CONTRIBUIÇÕES DA DISSERTAÇÃO

Retomando os objetivos específicos estabelecidos na Seção 1.3 do Capítulo 1, esta dissertação consolida as seguintes contribuições:

- a) a documentação de uma arquitetura de aquisição de dados industrial, baseada em controlador lógico programável e em um motor de aquisição containerizado, capaz de sincronizar temporalmente medições elétricas em nível de inversor e variáveis meteorológicas de uma estação solarimétrica, atendendo ao objetivo específico (a);
- b) a introdução e disponibilização pública do *dataset* BST-PV, um conjunto de dados de alta resolução temporal (5 minutos), com aproximadamente 2,16 milhões de registros distribuídos ao longo de 343 dias de operação real, que preenche a lacuna identificada na literatura quanto à ausência de dados que combinem simultaneamente medições em nível de inversor, variáveis meteorológicas de alta frequência e uma configuração *twin-plant* controlada, atendendo ao objetivo específico (b);
- c) a proposição e validação de um pipeline de pré-processamento fisicamente informado, que combina zeragem noturna baseada em cálculo astronômico de nascer e pôr do sol, interpolação linear para lacunas curtas e imputação multivariada via KNN para lacunas mais extensas, garantindo a consistência física das séries temporais resultantes, atendendo ao objetivo específico (c);
- d) o desenvolvimento de uma estratégia de engenharia de atributos temporais baseada em defasagens selecionadas a partir de funções de autocorrelação e correlação cruzada — e não de forma arbitrária —, incorporando conhecimento do domínio físico (como o atraso térmico do módulo fotovoltaico) à construção dos atributos de entrada dos modelos, atendendo ao objetivo específico (d);
- e) evidências empíricas robustas, obtidas sob condições meteorológicas idênticas entre os subsistemas, de que a dificuldade de previsão do sistema com rastreamento solar é condicional à estação do ano, sendo superior à do sistema fixo no verão e na primavera, equivalente no inverno e inferior no outono, atendendo ao objetivo específico (e);
- f) uma avaliação comparativa sistemática e em condições equivalentes entre algoritmos clássicos de aprendizado de máquina (*Random Forest*, XGBoost e LightGBM) e modelos baseados em LLM (Time-LLM, Chronos e Prophet) na previsão de geração fotovoltaica, em duas resoluções temporais distintas, demonstrando a superioridade ampla e quase integral dos primeiros — com uma única ressalva pontual e sem relevância prática, discutida na Seção 4.3.1 — e diagnosticando as limitações arquiteturais específicas de cada modelo de LLM avaliado, atendendo ao objetivo específico (f);
- g) a formulação de implicações práticas e recomendações concretas para a seleção de modelos, a priorização de etapas metodológicas e a calibração de incerteza em sistemas operacionais de previsão e despacho de energia fotovoltaica, atendendo ao objetivo específico (g).

O conjunto dessas contribuições foi materializado em três publicações científicas que documentam, de forma independente e complementar, cada etapa da pesquisa: a introdução do *dataset* BST-PV (19), a análise sazonal comparativa entre os subsistemas fixo e com rastreamento (60) e a avaliação crítica de modelos baseados em LLM frente a algoritmos clássicos (56).

5.3 LIMITAÇÕES DO TRABALHO

Não obstante as contribuições apresentadas, esta dissertação apresenta limitações que devem ser consideradas na interpretação de seus resultados e que, em alguns casos, já haviam sido apontadas ao longo dos capítulos anteriores.

Em primeiro lugar, há uma limitação de especificidade geográfica e climática: todos os dados utilizados nos três experimentos provêm de uma única planta fotovoltaica localizada no cerrado brasileiro, um clima de savana tropical com estações secas e chuvosas bem definidas. Embora o *dataset* BST-PV capture uma ampla variabilidade meteorológica dentro desse regime climático, a generalização dos padrões sazonais e das conclusões sobre a topologia de montagem identificados nesta dissertação para outras regiões climáticas — como climas temperados, desérticos ou equatoriais úmidos — requer validação adicional e não deve ser assumida *a priori*.

Em segundo lugar, a comparação entre os subsistemas fixo e com rastreamento, embora controlada quanto às condições meteorológicas, não incluiu variáveis que descrevam diretamente o estado mecânico do sistema de rastreamento, como o ângulo real do rastreador em cada instante ou indicadores explícitos de ativação do *backtracking*. A ausência dessas variáveis impede que os modelos capturem de forma explícita — em vez de apenas indireta, por meio do efeito que produzem sobre a irradiância POA — a componente determinística introduzida pelo algoritmo de controle do rastreador, o que pode estar subestimando o potencial de melhoria de desempenho para esse subsistema.

Em terceiro lugar, no que se refere à avaliação dos modelos baseados em LLM, os experimentos desta dissertação utilizaram os modelos Time-LLM, Chronos e Prophet em configurações que, embora tecnicamente fundamentadas, não esgotam o espaço de possibilidades dessas arquiteturas. Em particular, o Chronos foi avaliado em modo *zero-shot*, sem ajuste fino (*fine-tuning*) específico ao domínio fotovoltaico, e o Time-LLM foi avaliado com um único valor de comprimento de janela de contexto (`seq_len`), identificado nesta própria dissertação como uma limitação potencialmente superável. Os resultados obtidos, portanto, caracterizam o desempenho dessas arquiteturas nas configurações avaliadas, e não necessariamente o limite superior de seu desempenho possível no domínio fotovoltaico. Adicionalmente, a discussão sobre custo computacional apresentada na Seção 4.3.6 é de natureza qualitativa, fundamentada na arquitetura dos modelos avaliados, e não em medições sistemáticas de tempo de treinamento e de inferência sob condições de hardware

controladas — uma lacuna que trabalhos futuros podem preencher para quantificar com precisão a relação entre desempenho preditivo e custo de infraestrutura.

Em quarto lugar, o horizonte de previsão investigado nos três experimentos foi limitado a um único passo futuro (5 minutos ou 1 hora, conforme o experimento), não tendo sido avaliados horizontes de previsão multi-passo ou de prazo mais longo (por exemplo, previsão do dia seguinte com base em dados de previsão numérica do tempo). É justamente nesse cenário de horizontes mais longos que a literatura sugere que arquiteturas capazes de modelar dependências de longo alcance — como os próprios LLMs — poderiam, em princípio, oferecer vantagem competitiva ainda não observada nos experimentos de curto prazo aqui reportados.

Por fim, a seleção de variáveis de entrada nos Experimentos 1 e 2 baseou-se no critério de correlação de Pearson, uma medida de associação linear que, embora amplamente utilizada na literatura de previsão fotovoltáica, pode não capturar integralmente relações não lineares relevantes entre variáveis meteorológicas secundárias (como vento e precipitação) e a potência gerada, especialmente em condições de céu parcialmente nublado.

Uma limitação metodológica adicional, transversal aos três experimentos, é a ausência de testes formais de significância estatística nas comparações entre modelos. Todas as comparações de desempenho reportadas nesta dissertação — entre algoritmos de *ensemble*, entre estratégias de modelagem do Experimento 2 e entre modelos clássicos e LLMs no Experimento 3 — baseiam-se em estimativas pontuais de MAE, RMSE e R^2 , sem intervalos de confiança, testes de Diebold-Mariano, testes de Wilcoxon *signed-rank* ou procedimentos de *bootstrap* para quantificar a incerteza dessas estimativas. Essa é uma prática comum na literatura de aprendizado de máquina aplicada a séries temporais energéticas, mas constitui uma limitação real: por exemplo, o RF e o LGBM apresentam $R^2 = 0,8531$ idênticos no sistema fixo em 5 minutos no Experimento 3, e não há, com os dados aqui reportados, como determinar se essa proximidade reflete equivalência estatística genuína ou apenas coincidência amostral. Da mesma forma, diferenças pequenas como a inversão de liderança entre RF e LGBM no sistema com rastreamento em 1 hora (Seção 4.3.2) não podem ser caracterizadas como estatisticamente significativas sem testes formais. Embora essa limitação não comprometa as conclusões de maior magnitude desta dissertação — como a superioridade ampla e consistente dos modelos clássicos sobre os LLMs avaliados, ou o efeito sazonal dominante sobre a acurácia —, ela reduz o rigor estatístico das comparações mais sutis entre modelos de desempenho próximo, e sua incorporação é recomendada para trabalhos futuros que aprofundem essas comparações específicas.

5.4 TRABALHOS FUTUROS

A partir das limitações identificadas e das oportunidades reveladas ao longo da pesquisa, recomendam-se as seguintes direções para trabalhos futuros:

- a) **Extensão geográfica e temporal do *dataset*.** A ampliação do período de monitoramento da planta *Twin-Plant* para múltiplos anos permitiria investigar a estabilidade interanual dos padrões sazonais identificados, enquanto a replicação da metodologia em plantas localizadas em outras regiões climáticas brasileiras ou internacionais possibilitaria avaliar a generalização das conclusões sobre o impacto da topologia de montagem;
- b) **Incorporação de variáveis operacionais do rastreador.** A inclusão do ângulo de rastreamento instantâneo e de indicadores de ativação do *backtracking* como atributos de entrada dos modelos representa uma direção natural para investigar se a componente determinística do movimento do rastreador pode ser explicitamente aprendida, potencialmente reduzindo a lacuna de desempenho observada no sistema com rastreamento durante o verão e a primavera;
- c) **Ajuste fino de *foundation models* para o domínio fotovoltaico.** Em vez de utilizar o Chronos em modo *zero-shot*, trabalhos futuros podem investigar o impacto do ajuste fino desse e de outros *foundation models* de série temporal com dados de geração fotovoltaica, bem como uma busca sistemática pelo comprimento de janela de contexto ideal para o Time-LLM em diferentes resoluções temporais;
- d) **Integração de previsão numérica do tempo (NWP) como regressor exógeno.** A incorporação de variáveis de NWP, tanto em modelos clássicos quanto em arquiteturas baseadas em LLM, pode estender a validade dos resultados desta dissertação para horizontes de previsão mais longos, nos quais a informação puramente histórica e instantânea torna-se progressivamente menos informativa;
- e) **Avaliação de horizontes de previsão multi-passo.** A extensão da metodologia para previsão de múltiplos passos futuros simultâneos permitiria investigar se a capacidade de modelagem de dependências de longo alcance dos LLMs, não evidenciada nos horizontes de curto prazo avaliados nesta dissertação, oferece vantagem competitiva em horizontes operacionalmente relevantes para o despacho do dia seguinte;
- f) **Aplicações de diagnóstico e detecção de falhas.** Tal como apontado desde a introdução do *dataset* BST-PV, a configuração *Twin-Plant* e as medições em nível de inversor possuem potencial ainda não explorado nesta dissertação para aplicações de monitoramento de desempenho, detecção de falhas e identificação de anomalias, como

soiling e sombreamento parcial, a partir da comparação entre a geração esperada e a observada sob condições ambientais conhecidas;

- g) **Modelos híbridos físico-estatísticos.** A combinação explícita de modelos físicos de posicionamento do rastreador solar com modelos estatísticos de aprendizado de máquina, em arquiteturas híbridas, constitui uma direção promissora para incorporar a componente determinística do sistema de rastreamento sem abandonar a flexibilidade dos modelos de *ensemble* que se mostraram mais eficazes ao longo desta dissertação.

Em conjunto, essas direções de pesquisa futura reforçam o papel do *dataset* BST-PV — disponibilizado publicamente como resultado desta dissertação — como uma plataforma experimental de uso continuado para a comunidade de pesquisa em previsão e monitoramento de sistemas fotovoltaicos, ampliando o alcance de uma investigação que, nesta dissertação, avançou da constituição da infraestrutura de dados ao posicionamento crítico do estado da arte em modelagem preditiva.

REFERÊNCIAS

- 1 International Energy Agency. Renewables 2025: Analysis and forecast to 2030. Technical report, IEA, Paris, 2025. URL <https://www.iea.org/reports/renewables-2025>.
- 2 Omid Pedram, Ana Soares, and Pedro Moura. A review of methodologies for photovoltaic energy generation forecasting in the building sector. *Energies*, 18(18), 2025. doi: 10.3390/en18184727.
- 3 Jibo Wang, Zihao Zhang, Wenhao Xu, Yijin Li, and Geng Niu. Short-term photovoltaic power forecasting using a Bi-LSTM neural network optimized by hybrid algorithms. *Sustainability*, 17(12):5277, 2025. doi: 10.3390/su17125277.
- 4 Ruohan Li, Yiqun Xie, Xiaowei Jia, Dongdong Wang, Yanhua Li, Yingxue Zhang, Zhihao Wang, and Zhili Li. SolarCube: An integrative benchmark dataset harnessing satellite and in-situ observations for large-scale solar energy forecasting. *Advances in Neural Information Processing Systems*, 37:3499–3513, 2024.
- 5 Jacob T. Stid, Anthony D. Kendall, Annick Anctil, Jeremy Rapp, James C. Bingaman, and David W. Hyndman. A harmonized dataset of ground-mounted solar energy in the US with enhanced metadata. *Scientific Data*, 12(1):1586, 2025. doi: 10.1038/s41597-025-05026-2.
- 6 Ming Jin, Shiyu Wang, Lintao Ma, Zhixuan Chu, James Y. Zhang, Xiaoming Shi, Pin-Yu Chen, Yuxuan Liang, Yuan-Fang Li, Shirui Pan, et al. Time-LLM: Time series forecasting by reprogramming large language models. *arXiv preprint arXiv:2310.01728*, 2023. URL <https://arxiv.org/abs/2310.01728>.
- 7 Abdul Fatir Ansari, Lorenzo Stella, Caner Turkmen, Xiyuan Zhang, Pedro Mercado, Huibin Shen, Oleksandr Shchur, Syama Sundar Rangapuram, Sebastian Pineda Arango, Shubham Kapoor, Jasper Zschiegner, Danielle C. Maddix, Hao Wang, Michael W. Mahoney, Kari Torkkola, Andrew Gordon Wilson, Michael Bohlke-Schneider, and Yuyang Wang. Chronos: Learning the language of time series, 2024. URL <https://arxiv.org/abs/2403.07815>.
- 8 Sameer Al-Dahidi, Manoharan Madhilarasan, Loiy Al-Ghussain, Ahmad M. Abubaker, Adnan Darwish Ahmad, Mohammad Alrbai, Mohammadreza Aghaei, Hussein Alahmer, Ali Alahmer, Piero Baraldi, et al. Forecasting solar photovoltaic power production: A comprehensive review and innovative data-driven modeling framework. *Energies*, 17(16):4145, 2024. doi: 10.3390/en17164145.
- 9 Lipika Datta, Mohammad Rizwan, and Priyanka Anand. Comprehensive review and evaluation of machine learning approaches for solar PV output power forecasting. In *2023 International Conference on Computational Intelligence and Sustainable Engineering Solutions (CISES)*, pages 794–800, 2023. doi: 10.1109/CISES58720.2023.10183451.
- 10 Manvi Gupta, Archie Arya, Uday Varshney, Jishnu Mittal, and Anuradha Tomar. A review of PV power forecasting using machine learning techniques. *Progress in Engineering Science*, 2(1):100058, 2025. doi: 10.1016/j.pes.2025.100058.

- 11 Tiechui Yao, Jue Wang, Haoyan Wu, Pei Zhang, Shigang Li, Yangang Wang, Xuebin Chi, and Min Shi. A photovoltaic power output dataset: Multi-source photovoltaic power output dataset with Python toolkit. *Solar Energy*, 230:122–130, 2021. doi: 10.1016/j.solener.2021.10.053.
- 12 Hugo T. C. Pedro, David P. Larson, and Carlos F. M. Coimbra. A comprehensive dataset for the accelerated development and benchmarking of solar forecasting methods. *Journal of Renewable and Sustainable Energy*, 11(3), 2019. doi: 10.1063/1.5094494.
- 13 Matthew Boyd. Performance data from the NIST photovoltaic arrays and weather station. *Journal of Research of the National Institute of Standards and Technology*, 122:1, 2017. doi: 10.6028/jres.122.040.
- 14 Manajit Sengupta, Yu Xie, Anthony Lopez, Aron Habte, Galen Maclaurin, and James Shelby. The national solar radiation data base (NSRDB). *Renewable and Sustainable Energy Reviews*, 89:51–60, 2018. doi: 10.1016/j.rser.2018.03.003.
- 15 Dayin Chen, Xiaodan Shi, Mingkun Jiang, Shibo Zhu, Haoran Zhang, Dongxiao Zhang, Yuntian Chen, and Jinyue Yan. Selecting effective NWP integration approaches for PV power forecasting with deep learning. *Solar Energy*, 301:113939, 2025. doi: 10.1016/j.solener.2025.113939.
- 16 Anqi Li, Luling Liu, Shijie Li, Xihong Cui, Xuehong Chen, and Xin Cao. Global photovoltaic solar panel dataset from 2019 to 2022. *Scientific Data*, 12(1):637, 2025. doi: 10.1038/s41597-025-04984-9.
- 17 Sayeed Hasan, Andrei Blinov, Andrii Chub, and Dmitri Vinnikov. Solar PV generation and consumption dataset of an Estonian residential dwelling. *Scientific Data*, 12(1):481, 2025. doi: 10.1038/s41597-025-04743-w.
- 18 Xin Chen, Baojie Li, Jennifer L. Braid, Brandon Byford, Dylan J. Colvin, Andrew Glaws, Norman Jost, Benjamin Pierce, Salil Rabade, Martin Springer, et al. Open data sets for assessing photovoltaic system reliability. *Applied Energy*, 395:126132, 2025. doi: 10.1016/j.apenergy.2025.126132.
- 19 Arthur S. Rodrigues, Camille V. M. B. de Oliveira, Arthur C. Vargas Pinto, Matheus M. A. M. Ferreira, and Eduardo P. de Aguiar. A high-resolution twin-plant photovoltaic dataset for forecasting and system performance analysis. *Data in Brief*, 2025. Submetido à Elsevier.
- 20 Wen-Chang Tsai, Chia-Sheng Tu, Chih-Ming Hong, and Whei-Min Lin. A review of state-of-the-art and short-term forecasting models for solar PV power generation. *Energies*, 16(14):5436, 2023. doi: 10.3390/en16145436.
- 21 Mauladdawilah Husein, E. J. Gago, Hasan Balfaqih, and M. C. Pegalajar. Towards energy efficiency: A comprehensive review of deep learning-based photovoltaic power forecasting strategies. *Heliyon*, 10(13):e33419, 2024. doi: 10.1016/j.heliyon.2024.e33419.
- 22 A. Bugała, M. Zaborowicz, P. Boniecki, D. Janczak, K. Koszela, W. Czekala, and A. Lewicki. Short-term forecast of generation of electric energy in photovoltaic

- systems. *Renewable and Sustainable Energy Reviews*, 81:306–312, 2018. doi: 10.1016/j.rser.2017.08.019.
- 23 Mohammed H. Alsharif and Mohammad K. Younes. Evaluation and forecasting of solar radiation using time series adaptive neuro-fuzzy inference system: Seoul city as a case study. *IET Renewable Power Generation*, 13(10):1711–1723, 2019. doi: 10.1049/iet-rpg.2018.5669.
 - 24 M. Abumohsen, A. Y. Owda, M. Owda, and A. Abumihsan. Hybrid machine learning model combining of CNN-LSTM-RF for time series forecasting of solar power generation. *e-Prime — Advances in Electrical Engineering, Electronics and Energy*, 9: 100636, 2024. doi: 10.1016/j.prime.2024.100636.
 - 25 H. I. Aouidad et al. Machine learning-based short-term solar power forecasting: a comparative study. *Energy Informatics*, 7:1–18, 2024. doi: 10.1186/s40807-024-00115-1.
 - 26 A. K. Chaaban et al. A comparative study of machine learning approaches for solar power forecasting. *Energy Reports*, 2024. doi: 10.1016/j.egyr.2024.01.434.
 - 27 Y. Djeldjeli et al. Enhancing solar power forecasting with machine learning and feature selection strategies. *MethodsX*, 2024. doi: 10.1016/j.mex.2024.102438.
 - 28 Takuya Akiba, Shotaro Sano, Toshihiro Yanase, Takeru Ohta, and Masanori Koyama. Optuna: A next-generation hyperparameter optimization framework. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, pages 2623–2631, 2019. doi: 10.1145/3292500.3330701.
 - 29 Aleksei Mashlakov, Toni Kuronen, Lasse Lensu, Arto Kaarna, and Samuli Honkapuro. Assessing the performance of deep learning models for multivariate probabilistic energy forecasting. *Applied Energy*, 285:116405, 2021. doi: 10.1016/j.apenergy.2020.116405.
 - 30 Irena Koprinska, Mashud Rana, and Vassilios G. Agelidis. Correlation and instance based feature selection for electricity load forecasting. *Knowledge-Based Systems*, 82: 29–40, 2015. doi: 10.1016/j.knosys.2015.02.017.
 - 31 Hugo T. C. Pedro and Carlos F. M. Coimbra. Nearest-neighbor methodology for prediction of intra-hour global horizontal and direct normal irradiances. *Renewable Energy*, 80:195–204, 2015. doi: 10.1016/j.renene.2015.02.024.
 - 32 Cyril Voyant, Gilles Notton, Soteris Kalogirou, Marie-Laure Nivet, Christophe Paoli, Fabrice Motte, and Alexis Fouilloy. Machine learning methods for solar radiation forecasting: A review. *Renewable Energy*, 105:569–582, 2017. doi: 10.1016/j.renene.2016.12.095.
 - 33 Hugo T. C. Pedro and Carlos F. M. Coimbra. Assessment of forecasting techniques for solar power production with no exogenous inputs. *Solar Energy*, 86(7):2017–2028, 2012. doi: 10.1016/j.solener.2012.04.004.
 - 34 E. Skoplaki and J. A. Palyvos. On the temperature dependence of photovoltaic module electrical performance: A review of efficiency/power correlations. *Solar Energy*, 83(5):614–624, 2009. doi: 10.1016/j.solener.2008.10.008.

- 35 Mauladdawilah Husein, E. J. Gago, Hasan Balfaqih, and M. C. Pegalajar. Towards energy efficiency: A comprehensive review of deep learning-based photovoltaic power forecasting strategies. *Heliyon*, 10(13):e33419, 2024. doi: 10.1016/j.heliyon.2024.e33419.
- 36 Juan Ospina, Alvi Newaz, and M. Omar Faruque. Forecasting of PV plant output using hybrid wavelet-based LSTM-DNN structure model. *IET Renewable Power Generation*, 13(7):1087–1095, 2019. doi: 10.1049/iet-rpg.2018.5941.
- 37 Wencheng Liu and Zhizhong Mao. Short-term photovoltaic power forecasting with feature extraction and attention mechanisms. *Renewable Energy*, 226:120437, 2024. doi: 10.1016/j.renene.2024.120437.
- 38 Xiuli Xiang, Xingyu Li, Yaoli Zhang, and Jiang Hu. A short-term forecasting method for photovoltaic power generation based on the TCN-ECANet-GRU hybrid model. *Scientific Reports*, 14(1):6744, 2024. doi: 10.1038/s41598-024-57219-5.
- 39 Jinjiang Zhang, Liqing Hong, Shamsuddeen Nyako Ibrahim, and Yuanru He. Short-term prediction of behind-the-meter PV power based on attention-LSTM and transfer learning. *IET Renewable Power Generation*, 18(3):321–330, 2024. doi: 10.1049/rpg2.12855.
- 40 Cristiano G. M. Camandaroba, Camille V. M. B. de Oliveira, Caian D. de Jesus, Matheus A. M. Ferreira, Guilherme A. N. Pussente, Geraldo F. Neto, and Eduardo P. de Aguiar. Forecasting power generation in photovoltaic plants using artificial neural networks and transfer learning. 4(1), 2024.
- 41 Stéfano Frizzo Stefenon, Christopher Kasburg, Roberto Zanetti Freire, Fernanda Cristina Silva Ferreira, Douglas Wildgrube Bertol, and Ademir Nied. Photovoltaic power forecasting using wavelet neuro-fuzzy for active solar trackers. *Journal of Intelligent & Fuzzy Systems*, 40(1):1083–1096, 2021. doi: 10.3233/JIFS-200891.
- 42 Stéfano Frizzo Stefenon, Christopher Kasburg, Ademir Nied, Anne Carolina Rodrigues Klaar, Fernanda Cristina Silva Ferreira, and Nathiella Waldrigues Branco. Hybrid deep learning for power generation forecasting in active solar trackers. *IET Generation, Transmission & Distribution*, 14(23):5667–5674, 2020. doi: 10.1049/iet-gtd.2020.0469.
- 43 Mohamed R. Aboelmagd, Ali Selim, and Mamdouh Abdel-Akher. Forecasting of power generation in a single-axis solar tracking PV system using an enhanced artificial neural network-based method. *IET Renewable Power Generation*, 19(1):e70100, 2025. doi: 10.1049/rpg2.70100.
- 44 M. R. Sharaby et al. Performance evaluation of fixed and sun-tracking photovoltaic systems with cooling techniques. *Solar Energy*, 2025.
- 45 R. Sadeghi et al. A review and comparative analysis of solar tracking systems. *Renewable Energy Reviews*, 2025.
- 46 Waqas Ahmed, Jamil Ahmed Sheikh, and M. A. Parvez Mahmud. Impact of PV system tracking on energy production and climate change. *Energies*, 14(17):5348, 2021. doi: 10.3390/en14175348.

- 47 Marcos A. Ponce-Jara, Carlos Velásquez-Figueroa, María Reyes-Mero, and Catalina Rus-Casas. Performance comparison between fixed and dual-axis sun-tracking photovoltaic panels with an IoT monitoring system in the coastal region of Ecuador. *Sustainability*, 14(3):1696, 2022. doi: 10.3390/su14031696.
- 48 Zonglei Chen, Minbo Ma, Tianrui Li, Hongjun Wang, and Chongshou Li. Long sequence time-series forecasting with deep learning: A survey. *Information Fusion*, 97: 101819, 2023. doi: 10.1016/j.inffus.2023.101819.
- 49 Chengjie Zhou, Yufeng Wang, Jianhua Ma, and Qun Jin. STCA-LLM: Spatial-temporal cross-attention large language model for wind speed forecasting. *IEEE Internet of Things Journal*, 12(21):45411–45422, 2025. doi: 10.1109/JIOT.2025.3599836.
- 50 Nate Gruver, Marc Finzi, Shikai Qiu, and Andrew Gordon Wilson. Large language models are zero-shot time series forecasters, 2024. URL <https://arxiv.org/abs/2310.07820>.
- 51 Hao Xue and Flora D. Salim. PromptCast: A new prompt-based learning paradigm for time series forecasting. *IEEE Transactions on Knowledge and Data Engineering*, 36(11):6851–6864, 2024. doi: 10.1109/TKDE.2023.3342137.
- 52 Sidney Shapiro and Burhanuddin Panvelwala. Prophet as a reproducible forecasting framework: A methodological guide for business and financial analytics. *arXiv preprint arXiv:2601.05929*, 2026. URL <https://arxiv.org/abs/2601.05929>.
- 53 Rongquan Zhang, Siqi Bu, Gangqiang Li, and Jing Qiu. Probabilistic prediction of photovoltaic power: A multi-task learning and large language model-based approach. *Renewable Energy*, 256:124004, 2026. doi: 10.1016/j.renene.2025.124004.
- 54 Zehuan Hu, Yuan Gao, Luning Sun, and Masayuki Mae. A novel attention-enhanced LLM approach for accurate power demand and generation forecasting. *Renewable Energy*, 252:123465, 2025. doi: 10.1016/j.renene.2025.123465.
- 55 Lei Wang, Keyao Dong, and Xiaoyong Zhao. A novel LLM time series forecasting method based on integer-decimal decomposition. *Scientific Reports*, 15(1):23004, 2025. doi: 10.1038/s41598-025-07018-5.
- 56 Arthur S. Rodrigues, Camille V. M. B. de Oliveira, Arthur C. Vargas Pinto, Matheus A. M. Ferreira, and Eduardo P. de Aguiar. Avaliação de modelos baseados em LLM para previsão de potência solar em usina Twin-Plant com comparação a algoritmos clássicos de aprendizado de máquina. In *XLIV Simpósio Brasileiro de Telecomunicações e Processamento de Sinais (SBrT)*, Salvador, BA, 2026. Submetido.
- 57 Simon Kennedy. Astral: Python calculations for the position of the sun and moon. <https://astral.readthedocs.io/>, 2022. Acesso em: 17 mar. 2026.
- 58 Claudio Mantuano, Olalekan Omoyele, Maximilian Hoffmann, Jann Michael Weinand, Massimo Panella, and Detlef Stolten. Data imputation methods for intermittent renewable energy sources: Implications for energy system modeling. *Energy Conversion and Management*, 339:119857, 2025. doi: 10.1016/j.enconman.2025.119857.

- 59 Charu C. Aggarwal. *Data Mining: The Textbook*. Springer, 2015. doi: 10.1007/978-3-319-14142-8.
- 60 Arthur S. Rodrigues, Camille V. M. B. de Oliveira, Arthur C. Vargas Pinto, Matheus A. M. Ferreira, and Eduardo P. de Aguiar. Previsão de geração fotovoltaica em sistemas fixos e com seguidor solar: Uma análise comparativa em configuração Twin-Plant sob condições de operação real. In *Congresso Brasileiro de Automática (CBA)*, 2025. Submetido.